

Contents

ETD 优于 Baseline 的实验结果摘录 (R37–R41) 1

- 1. Qwen3-8B: R39C 多选题主评测 (r39c_final_qwen3.json) 1
- 2. Qwen3-8B: R38 全基准信号法 (r38_final_results.json 摘要) 2
- 3. Qwen3-8B: R40 BBH (6 子任务 $\times$ N=50) 与 GSM8K (N=50) 2
- 4. Qwen3-8B: R41 (MC + BBH, 小样本) 3
- 5. Llama3-8B / Gemma2-2B (效果不佳: 极短概述) 3
- 6. 早期轮次 (R32–R36) 与「未过 Baseline」的合并说明 3

数据与复现 7

ETD 优于 Baseline 的实验结果摘录 (R37–R41)

本文只展开在已保存的 JSON 结果中, 某 ETD 选窗/信号方法的准确率严格高于同设置 Baseline 的情形; 若未超过 Baseline 或整体为负向, 则合并为末节极短概述, 不展开表格细节。

约定: $\Delta = \text{accuracy}_{\text{method}} - \text{accuracy}_{\text{baseline}}$ 。插图路径相对于本文件所在目录 experiments/。

1. Qwen3-8B: R39C 多选题主评测 (r39c_final_qwen3.json)

评测规模: 各 benchmark N=100 (TruthfulQA 为 N=50)。方法含义: neg_cos_am_calib (负 $\cos(a, m)$ 标定窗)、emp_logit_fixed (标定集 logit 增益搜窗)、neg_cos_am_ps_nt (逐样本负 $\cos(a, m)$ + 架构内 n_t 搜索)。sweep_best 为 R30 扫参最优固定窗 (上界参照, 非无参方法)。

1.1 相对 Baseline 有增益的方法 (逐项)

下表仅保留至少一种信号法满足 $\Delta > 0$ 的 benchmark; 数值保留两位小数。

Benchmark	Baseline	最佳信号法 (若有)	Acc	Δ	备注
BoolQ	0.82	emp_logit_fixed	0.90	+0.08	同时优于 sweep_best (0.87)
BoolQ	0.82	neg_cos_am_calib	0.86	+0.04	
BoolQ	0.82	neg_cos_am_ps_nt	0.85	+0.03	
TruthfulQA	0.32	emp_logit_fixed / neg_cos_am_ps_nt	0.34	+0.02	neg_cos_am_calib 与 baseline 持平
CSQA	0.64	neg_cos_am_calib	0.65	+0.01	emp_logit_fixed 与 baseline 持平
MMLU-HS-Math	0.40	neg_cos_am_calib	0.41	+0.01	sweep_best 为 +0.03; emp_logit_fixed 低于 baseline
AGIEval-Gaokao-MathQA	0.52	emp_logit_fixed / neg_cos_am_ps_nt	0.57	+0.05	neg_cos_am_calib 与 sweep_best 同为 0.54 (+0.02)
LogiQA	0.36	emp_logit_fixed	0.42	+0.06	
LogiQA	0.36	neg_cos_am_ps_nt	0.39	+0.03	
LogiQA	0.36	neg_cos_am_calib	0.38	+0.02	

ARC-Challenge: neg_cos_am_calib 与 emp_logit_fixed 与 Baseline 同为 0.56; 仅 sweep_best 为 0.58 (+0.02)。GPQA-Diamond: 三种信号法均 低于 Baseline (0.38), 不展开。

1.2 图示 (Qwen3 / R39C)




Figure 1: Qwen3 R39C 各 Benchmark 准确率条形图




Figure 2: Qwen3 相对 Baseline 的 Δacc 热力图

2. Qwen3-8B: R38 全基准信号法 (r38_final_results.json 摘要)

明显优于 Baseline 的亮点: MMLU-HS-Math 上 `calib_onset8` 达到 0.45, 相对 Baseline 0.40 为 +0.05, 且高于该任务上的 `sweep_best` (0.43)。CSQA 上 `persample_cos8` 0.68、`calib_global8` 0.67 均高于 Baseline 0.64。

其余 benchmark 上各信号法多为持平或低于 `sweep_best`; 整体不另占篇幅。

2.1 图示 (R38)

3. Qwen3-8B: R40 BBH (6 子任务 $\times$ N=50) 与 GSM8K (N=50)

3.1 BBH: 子任务层面 $\Delta > 0$ 汇总

子任务 (简名)	Baseline	方法	Acc	Δ
boolean_expressions	0.90	neg_cos_am_calib	0.92	+0.02

子任务（简名）	Baseline	方法	Acc	Δ
boolean_expressions	0.90	emp_logit_fixed	0.94	+0.04
causal_judgement	0.58	emp_logit_fixed	0.62	+0.04
disambiguation_qa	0.48	neg_cos_am_calib	0.50	+0.02
disambiguation_qa	0.48	emp_logit_fixed	0.58	+0.10
logical_deduction_three_objects	0.82	neg_cos_am_calib	0.86	+0.04
logical_deduction_three_objects	0.82	emp_logit_fixed	0.86	+0.04
object_counting	0.48	neg_cos_am_calib	0.52	+0.04

date_understanding 上三种 ETD 法均未超过 Baseline (0.74) ; causal_judgement / object_counting 上 neg_cos_am_ps_nt 未过 Baseline——略。

3.2 GSM8K (exact_match)

方法	exact_match	Δ vs Baseline
Baseline	0.90	—
neg_cos_am_calib	0.94	+0.04
emp_logit_fixed / neg_cos_am_ps_nt	0.90	0

3.3 图示 (R40 / Qwen3)

4. Qwen3-8B: R41 (MC + BBH, 小样本)

R41 中 BBH 六子任务宏平均 (r41_qwen3_reflux_jac.json, 各子任务 N=12) :

方法	BBH 宏平均 acc	Δ vs Baseline
Baseline	0.6528	—
neg_cos_am_calib	0.7361	+0.0833
emp_logit_fixed	0.7083	+0.0556
neg_cos_am_prop_attn	0.6944	+0.0417
reflux_rho_gate	0.6667	+0.0139

MC 三任务 (BoolQ / ARC-C / GPQA, N=25) 上多数法与 Baseline 持平或方差大; 其中 **ARC-C** 上 emp_logit_fixed 0.56 相对 Baseline 0.52 为 **+0.04**, neg_cos_am_calib 低于 Baseline (不展开)。

5. Llama3-8B / Gemma2-2B (效果不佳: 极短概述)

Llama3-8B (r39c_final_llama3.json) : 多数 benchmark 上信号法 **未稳定超过** sweep_best; 相对 Baseline 的 **单独正增益** 仅零星出现 (例如 GPQA 上 emp_logit_fixed 0.39 vs baseline 0.29 等), 整体以扫参窗为参照更稳妥。

Gemma2-2B (r39c_final_gemma2.json) : neg_cos_am_calib 在 BoolQ 等任务上 **明显低于** Baseline; emp_logit_fixed 多数为持平。不展开。

6. 早期轮次 (R32–R36) 与「未过 Baseline」的合并说明

R32–R33 在 **per-sample Spearman** 上未得到稳定显著相关; R34 主要贡献为 **几何信号** (如 $\cos(a, m)$) 与 T-block 的定性对齐。R35 交换子 **范数** 与 T-block 不对齐; R36 的 **directional_advantage** 未形成可靠的「过 Baseline 选层」产品结论。上述内容 **不另附表**; 若需完整推导与图表, 见 ETD_R32_to_R41_Comprehensive_Report.md。




Figure 3: R38 全 Benchmark 条形图




Figure 4: R38 Δ acc 热力图




Figure 5: GSM8K exact_match 对比




Figure 6: BBH 各子任务准确率热力图 (含 baseline 与三法)

R40 BBH: accuracy by method vs baseline




Figure 7: BBH 按模型分组的 Accuracy




Figure 8: R41 各条件准确率条形图

数据与复现

- 主要来源: experiments/results/r39c_final_qwen3.json、r38_final_results.json、r40_bbh_gsm8k_qwen3_8b.json、r4
- PDF 生成: bash experiments/export_positive_vs_baseline_pdf.sh (与主报告共用 pandoc + xelatex + Noto CJK)。