

Contents

ETD 信号探索研究综合报告：R32 至 R41 1

目录 1

1. 背景：ETD 算法与冠军配置 2

2. R31 遗留问题：一阶信号的系统性失败 3

3. R32：从一阶失败到二阶信息论——泰勒-海森理论分析 3

4. R33：FFN 慢权重相变与注意力快权重幂迭代信号 6

5. R34：方向与跨模块交叉交互信号 13

6. R35：Attention-FFN 非对易交换子实验 18

7. R36：方向特异性传播增益实验 22

8. R37：信号引导 ETD 选层（过渡实验） 29

9. R38：全 Benchmark 信号优化实验 29

10. R39：跨架构 ETD 根因分析与信号筛选 32

11. R40：BBH + GSM8K 三模型评测 36

12. R41：回流敏感度与 Jacobian 衰减复合信号 41

13. 纵向总结：十轮迭代的信号探索轨迹 43

附录 A：参数配置汇总 45

ETD 信号探索研究综合报告：R32 至 R41

研究对象：ETD (Early Thinking Deepening) ——一种无需重新训练、通过在推理期将 Transformer 中间层组成的“T-block”重复执行 k 次以增强模型推理能力的方法。

本文范围：R32 至 R41 共 10 轮迭代实验，聚焦“如何找到一个可靠的逐样本信号，用来预测某个特定窗口对当前输入

核心模型：Qwen3-8B（36 层，隐藏维度 4096，中间层 11264），并在 R38 之后扩展至 Llama3-8B 与 Gemma2-2B。

评测基准：BoolQ、ARC-C、CSQA、TruthfulQA、MMLU-HS-Math、GPQA-Diamond、AGIEval-Gaokao-MathQA、LogiQA，以及 BBH（6 子任务）和 GSM8K。

附图路径说明（与 ETD_Research_Report.md 一致）

本文件与 ETD_Research_Report.md 位于同一目录：loop_layer/experiments/。文中所有插图使用 **相对该目录** 的路径，形式为：

figures/<文件名或子目录>/...png

与主报告中的写法相同，例如 figures/r20_dashboard.png。Markdown 预览会把链接解析为「当前 .md 文件所在目录」下的相对路径，从而正确找到 experiments/figures/ 下的图片。

请勿使用以 /root/ 或 autodl-tmp/... 开头的绝对路径作为图片链接——在多数 Markdown 预览器中会无法加载。

目录

1. 背景：ETD 算法与冠军配置
2. R31 遗留问题：一阶信号的系统性失败
3. R32：从一阶失败到二阶信息论——泰勒-海森理论分析
4. R33：FFN 慢权重相变与注意力快权重幂迭代信号
5. R34：方向与跨模块交叉交互信号
6. R35：Attention-FFN 非对易交换子实验
7. R36：方向特异性传播增益实验
8. R37：信号引导 ETD 选层（过渡实验）
9. R38：全 Benchmark 信号优化实验
10. R39：跨架构 ETD 根因分析与信号筛选
11. R40：BBH + GSM8K 三模型评测
12. R41：回流敏感度与 Jacobian 衰减复合信号
13. 纵向总结：十轮迭代的信号探索轨迹

1. 背景：ETD 算法与冠军配置

1.1 ETD 算法描述

ETD 将推理过程分为三个阶段:

Input → [E-block: 层 0..n_e-1] → [T-block: 层 n_e..n_e+n_t-1]^k → [D-block: 剩余层] → Output
 固定执行一次 重复执行 k 次 固定执行一次

T-block 每次迭代的更新公式 (含阻尼系数 α) :

$$h_{\text{new}} = \alpha \cdot T(h) + (1 - \alpha) \cdot h_{\text{prev}}, \quad \alpha = \min\left(1, \frac{6}{n_t}\right)$$

核心参数含义如下:

参数	含义	典型取值
n_e (t_start)	T-block 起始层编号	8 (R30 BoolQ 最优)
n_t	T-block 层数	2-20
k	T-block 重复次数	2
α	阻尼系数	自适应, 随 n_t 调整

1.2 冠军配置与 R30 扫参最优窗口

经过 R2-R31 的系统探索, 各 benchmark 的扫参最优窗口 (sweep best) 如下:

Benchmark	t_start (n_e)	t_stop (n_e+n_t)	n_t
BoolQ	8	22	14
ARC-C	14	20	6
TruthfulQA	16	19	3
CSQA	10	22	12
MMLU-HS-Math	10	18	8
GPQA-Diamond	18	20	2
AGIEval-Gaokao-MathQA	13	20	7
LogiQA	14	19	5

这8个窗口在不同 benchmark 间跨度极大 (t_start 从8到18, n_t 从2到14), 意味着没有一个固定窗口能普遍最优。信

1.3 R31 确立的核心矛盾

在 R32 开始之前, R29-R31 已经系统收集了 18 个一阶信号 (norm_delta、entropy、logit_lens_KL、head_specializat 等) 的 Spearman 相关性。结论:

- **per-sample 相关**: 所有信号与 oracle_gain 的 Spearman $|\rho| \leq 0.14$ (信息量 ≈ 0.01 bits)
- **benchmark 级别相关**: 最高 logit_lens_jsd_vel_val_L10 的 $|\rho| = 0.586$, 但这只是 4 个数数据点
- **R31 最终验证**: 所有自适应信号路由变体的 macro ≤ 0.290 , 而 Champion 固定配置 (0.4375) 始终最优

1.4 全文记号与算子约定 (阅读后续「信号字典」前请先读本节)

以下记号在 R32-R41 各节中反复出现, 这里统一写出, 避免同一符号在不同轮次被赋予不同含义。

(1) **向量与范数。** 用 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^d$ 表示隐藏空间或 logits 空间中的向量（实现中通常取 **最后一个 token** 位置的向量，除非另有说明）。欧氏范数记为 $\|\mathbf{u}\|_2$ ，内积记为 $\mathbf{u}^\top \mathbf{v}$ 。为数值稳定，实现里会加小常数 $\varepsilon \geq 0$ 。

(2) 余弦相似度。

$$\text{cos_sim}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2 + \varepsilon}.$$

(3) 单层 Qwen3 风格 Pre-LN 残差块（与代码 hook 一致）。记第 ℓ 层输入为 $\mathbf{h}_\ell^{\text{in}}$ ，经 LN1 与 Self-Attention 得到注意力子层输出（残差相加前）为 $\mathbf{a}_\ell$ ，经 LN2 与 MLP 得到 FFN 子层输出（残差相加前）为 $\mathbf{m}_\ell$ ，则

$$\mathbf{h}_\ell^{\text{post-attn}} = \mathbf{h}_\ell^{\text{in}} + \mathbf{a}_\ell, \quad \mathbf{h}_{\ell+1} = \mathbf{h}_\ell^{\text{post-attn}} + \mathbf{m}_\ell.$$

下文凡写 $\mathbf{a}_\ell, \mathbf{m}_\ell$ ，均指残差相加之前的注意力输出与 MLP 输出，与 exp_r34/exp_r35 中 hook 捕获的张量一致。

(4) **logit lens**。记最终 LayerNorm 与词表映射为 $\text{LM}(\cdot) = W_{\text{vocab}} \text{LN}_f(\cdot)$ 。对任意隐藏状态 $\mathbf{h}$ ， $\text{LM}(\mathbf{h})$ 给出「若在此处直接读出 logits」的分布，用于观察中层语义漂移。

(5) **Jensen-Shannon 散度 (JSD)**。对同一位置上的两个概率分布 P, Q （例如两次前向的 $\text{softmax}(\text{logits})$ ），

$$\text{JSD}(P, Q) = \frac{1}{2} \text{KL}(P \| M) + \frac{1}{2} \text{KL}(Q \| M), \quad M = \frac{1}{2}(P + Q).$$

R36/R41 中「对 logits 做扰动后再算 JSD」即用该度量刻画**输出分布**对微扰的敏感程度。

(6) **oracle_gain / sweep_best**。oracle_gain 表示在固定评测协议下，Champion ETD 相对 Baseline 的逐样本正确性变化 $\{-1, 0, +1\}$ ；sweep_best 表示在 R30 网格上搜索得到的 **benchmark 级** 最优 (n_e, n_t) 窗口，用作信号对齐的参照，而非逐样本标签。

2. R31 遗留问题：一阶信号的系统性失败

2.1 失败现象

实验轮次	核心结论
R29	10 类信号的 Lite Probe: per-sample oracle_gain 相关 $r \leq 0.14$
R30（过渡）	18 信号 Spearman 相关, benchmark 级最高 $ \rho =0.586$ (logit_lens_jsd_val_L10)，但样本数=4，不可信
R31	全面证伪 H1/H2/H3：所有自适应变体 macro ≤ 0.290 , Champion 固定配置 (0.4375) 始终最优

2.2 Benchmark 间信号矛盾

一个关键现象揭示了一阶信号失败的结构性问题——在 benchmark 级别，信号几乎无法区分不同任务的最优 t_start：

对比组	信号余弦相似度	最优 t_start 差异
ARC-C $\leftrightarrow$ MMLU	0.9992（几乎相同）	14 vs 10（差 4 层）
TruthfulQA $\leftrightarrow$ CSQA	0.9995（几乎相同）	16 vs 10（差 6 层）

两个 benchmark 的信号曲线几乎完全重叠，但其最优 t_start 却相差 4–6 层。这种矛盾不是偶然，而是由 Transformer 内部动力学的结构性原因导致的。

3. R32：从一阶失败到二阶信息论——泰勒-海森理论分析

3.1 理论：为什么一阶探针注定失败

R32 从理论上给出了一阶信号失败的根本解释。令 T-block 为非线性映射 $F(h)$ （所有残差子层的叠加）：

第一次前向 (Baseline)： $\Delta_0 = F(h_0)$ ，即所有一阶信号测量的对象

ETD 第二次循环引入的净扰动（Taylor 展开）：

$$\delta_{\text{ETD}} = F(h_1) - F(h_0) = J_F(h_0)\Delta_0 + \frac{1}{2}\Delta_0^T H_F(h_0)\Delta_0 + O(\|\Delta_0\|^3)$$

判死刑点：所有历史一阶信号（norm_delta、entropy、logit_lens_KL等）测量的是 Δ_0 的零阶和一阶标量属性（如 $\|\Delta_0\|$ 、 $H(\text{softmax}(\Delta_0))$ ），而 ETD 是否翻转 Logits 取决于 δ_{ETD} 经过 Decoder 传播后的**方向**，即 $J_F(h_0)$ 和 $H_F(h_0)$ 的作用结果。换言之，一阶信号与 ETD 增益之间存在根本性的**信息鸿沟**。

3.2 二次前向探针（2-Pass Probe）的计算流程

R32 的核心想法是：**不要只用第一次前向里看见的 Δ_0** ，而是再跑一遍 T-block，用 δ 近似捕捉 $J_F\Delta_0$ 与二阶项的贡献。

将 T-block 整体记为非线性算子 $F: \mathbb{R}^d \rightarrow \mathbb{R}^d$ （把 T-block 入口的隐藏状态映射到 T-block 出口的增量，实现中在**最后一层 token** 上聚合）。**Pass 0** 在入口状态 $\mathbf{h}_0$ 上执行一次 T-block：

$$\Delta_0 = F(\mathbf{h}_0).$$

Pass 1 将 T-block 入口更新为 $\mathbf{h}_1 = \mathbf{h}_0 + \Delta_0$ （与 ETD 第一步一致），再计算

$$\delta = F(\mathbf{h}_1) - F(\mathbf{h}_0).$$

Taylor 展开给出（形式化地写出「为何叫二阶探针」）：

$$\delta = J_F(\mathbf{h}_0) \Delta_0 + \frac{1}{2} H_F(\mathbf{h}_0)[\Delta_0, \Delta_0] + O(\|\Delta_0\|^3).$$

因此 δ 同时携带**一阶方向导数与曲率（Hessian 作用）**的信息；而历史一阶信号只盯着 Δ_0 的长度、熵等标量，天然看不到 δ 中与 J_F, H_F 相关的部分。

若在同一 T-block 内**逐层**记录子层增量 $\Delta_{0,\ell}$ 、 δ_ℓ （实现与 r32_phase* 脚本一致），还可定义逐层收缩剖面 $r_c(\ell)$ ，用于「临界层」假说检验。

3.3 R32 信号字典：公式、实现要点与直觉

以下每条信号均在**单次样本、最后一 token** 上计算（与 R32 实验协议一致），再与 oracle_gain 做 Spearman 相关或用于层位回归。

(S1) 全局收缩率 rc_global 公式：

$$r_c^{\text{global}} = \frac{\|\delta\|_2}{\|\Delta_0\|_2 + \varepsilon}.$$

直觉：若把一次 T-block 步进看成 Banach 迭代的一步， $\|\delta\| \ll \|\Delta_0\|$ （即 $r_c \ll 1$ ）暗示映射在局部**收缩**，重复迭代可能稳定到不动点附近；若 $r_c > 1$ ，局部可能**扩张**，迭代更像「放大噪声」。**局限：**

该比值是 Rayleigh 型量 $\|\Delta_0\|$ 方向上的「等效增益」，当 Δ_0 方向在样本间近乎随机、而 J_F 谱主要由权重决定时， r_c^{global} 会退化为**权重谱信息**，样本间方差极小（本实验 std ≈ 0.02 ），从而无法携带「本题是否该开 ETD」的 per-sample 信息。

(S2) 逐层收缩率 $r_c(\ell)$ 与 max_rc / 临界层 公式（第 ℓ 层）：

$$r_c(\ell) = \frac{\|\delta_\ell\|_2}{\|\Delta_{0,\ell}\|_2 + \varepsilon}.$$

派生量 max_rc（用于与 oracle t_{start} 对齐）：常取 $\ell \mapsto r_c(\ell)$ 的**最大值所在层** $\ell^* = \arg \max_\ell r_c(\ell)$ 作为「最扩张层」的代理；统计文件中的 max_rc 一行即对应将该标量或层索引与增益做相关。

直觉：若 ETD 应插在「Jacobian 谱半径最大、动力学最剧烈」的层段，则 $r_c(\ell)$ 峰值应对齐各 benchmark 的扫参最优 t_{start} 。**实验结论：**多数任务上 $\arg \max_\ell r_c(\ell)$ 被**锁在浅层**（例如均值 ≈ 8 ），与 TruthfulQA / ARC-C 等需要更晚窗口的事实矛盾，说明「**最剧烈**」 $\neq$ 「**最值得循环**」。

(S3) 全局方向对齐度 **theta_global** 公式：

$$\theta^{\text{global}} = \cos_{\text{sim}}(\Delta_0, \delta).$$

直觉： $\theta > 0$ 表示第二次 T-block 产生的增量 δ 与第一次增量 Δ_0 **同向**，迭代像是在「沿同一坡向继续爬」； $\theta < 0$ 表示第二次修正 **反向**，有振荡风险。**局限：** 该量仍只比较 **两次 T-block 增量之间的夹角**，未把 Decoder 后半段对 logits 的放大/旋转纳入；因此与 **oracle_gain** 的相关仍弱。

(S4) 逐层方向对齐与 **mean_theta_layers** 公式：

$$\theta(\ell) = \cos_{\text{sim}}(\Delta_{0,\ell}, \delta_\ell), \quad \bar{\theta} = \frac{1}{|\mathcal{L}|} \sum_{\ell \in \mathcal{L}} \theta(\ell)$$

其中 $\mathcal{L}$ 为 T-block 内参与平均的层集合（实现中取 T-block 层索引集合）。

直觉： 用多层平均平滑单层噪声，看整体迭代是否「自治」。若某些层 $\theta(\ell)$ 振荡而均值仍接近 0，则平均会掩盖真正关键的

(S5) **Logit 空间对齐 logit_align** 公式：将 Δ_0, δ 通过同一线性头映射到词表维（实现中可用 **lm_head** 作用在「仅由增量引起的 logits 变化」或其近似）：

$$\text{logit_align} = \cos_{\text{sim}}(\text{LM_vec}(\Delta_0), \text{LM_vec}(\delta)),$$

其中 $\text{LM_vec}(\cdot)$ 表示把隐藏增量投影到 logits 空间的具体实现（与 **r32** 代码一致即可）。

直觉： 隐藏空间中的同向，经 LayerNorm 与 W_{vocab} 后未必仍同向；该信号直接问「**输出竞争方向**」上两次增量是否一致。仍只依赖 Δ_0, δ 的**一阶投影**，未建模 Decoder 深层非线性。

(S6) **Hessian 代理量 hessian_proxy** 公式（正交残差型代理，与计划文档一致）：令 Π_{Δ_0} 为沿 Δ_0 的正交投影算子，

$$\text{hessian_proxy} = \|(\mathbf{I} - \Pi_{\Delta_0}) \delta\|_2 = \left\| \delta - \frac{\Delta_0 \Delta_0^\top}{\|\Delta_0\|_2^2 + \varepsilon} \delta \right\|_2.$$

直觉： 若 δ 几乎完全落在 Δ_0 张成的一维子空间内，则高阶曲率项「不可见」，代理量接近 0；若 δ 在正交方向上仍有显著分量，说明**非共线弯曲**明显，二阶效应可能更强。**局限：** 这是**粗代理**，不能等同于真实 Hessian 范数；且与 θ 存在代数耦合（同一 δ 被多种方式切片）。

(S7) **n_expanding** (扩张层计数类派生量) **直觉定义：** 统计满足 $r_c(\ell) > 1$ （或高于某阈值）的层数，作为「局部扩张」JSON 中该字段出现 NaN 表示在对应子集上未稳定定义或未写入；解读结果时应忽略或单独重算。

3.4 R32 实验结果

阶段 0 (N=20, 可视化诊断)

对 4 个 benchmark 提取逐层收缩率曲线 $r_c(l)$ ，结果见下图。

阶段 1 (N=200/benchmark, Spearman 假设检验)

在 N=200 样本的规模下，对 7 个二阶信号与 **oracle_gain** 做 Spearman 相关性检验。结果如下：

信号	BoolQ	ARC-C	CSQA	TruthfulQA
rc_global	0.046	-0.025	-0.058	0.093
theta_global	0.016	0.009	0.097	-0.041

信号	BoolQ	ARC-C	CSQA	TruthfulQA
logit_align	-0.032	0.085	-0.022	-0.035
max_rc	-0.046	-0.061	0.075	-0.118
mean_theta_layers	-0.044	-0.004	0.109	0.012
hessian_proxy	-0.016	-0.009	-0.097	0.041

所有 p 值均 > 0.05 （无统计显著性），最高 $|\rho| = 0.118$ （TruthfulQA max_rc），未超越一阶信号的历史天花板 0.14。

临界层定位（H_critical_layer）的预测误差：

Benchmark	Oracle t_start	预测值 (argmax rc)	MAE
BoolQ	8	8.0	0.0 ✓
ARC-C	14	8.56	5.44 ☒
CSQA	10	8.0	2.0 ✓
TruthfulQA	16	8.12	7.88 ☒

结论：R32 的二阶信号在 per-sample 层面依然无法有效预测 ETD 增益。rc_global 的样本间 std ≈ 0.02 ，与模型权重属性锁定，本质上不是输入依赖的。

3.5 R32 核心教训

rc 信号的根本缺陷： $r_c \approx \sqrt{\Delta_0^T J^T J \Delta_0 / \|\Delta_0\|^2}$ ，当 Δ_0 方向接近均匀分布时， r_c 趋近于 J_F 的平均谱半径——这是模型权重的固定属性，与输入无关。2-Pass 的计算量（约 2x Baseline）换来的信息量几乎为零。

4. R33: FFN 慢权重相变与注意力快权重幂迭代信号

4.1 动机：寻找真正的输入依赖信号

R32 失败的根本原因是 rc 本质上测量的是模型权重属性而非输入属性。R33 重新回到物理机制，从两个天然具有输入依赖性

FFN 慢权重（Gating 结构）：FFN 的局部雅可比矩阵受激活集 $\Omega(x)$ 约束：

$$J_{\text{FFN}}(h) = \sum_{i \in \Omega(x)} v_i k_i^T \cdot \sigma'(k_i^T h_0(x))$$

其中 $\Omega(x) = \{i : |\text{SiLU}(W_{\text{gate}} \cdot h_0(x))_i| > \text{threshold}\}$ 完全由输入决定。不同样本激活不同的 key 子空间，FFN Gini 系数直接量化了 $\Omega(x)$ 的结构。

Attention 快权重（Context Matrix）：

$$W_{\text{fast}}(x) = \sum_j \text{softmax}(q \cdot k_j / \sqrt{d}) \cdot v_j k_j^T$$

这个算子百分之百由当前输入上下文动态构造，不同样本有截然不同的谱结构。

4.2 R33 信号字典：公式、实现要点与直觉

以下信号均在层 ℓ 、最后一 token 上从 hook 张量计算；门控激活记为 $\mathbf{g}_\ell \in \mathbb{R}^{d_{\text{tr}}}$ （SiLU 后的 gate 通道，与 mlp.act_fn 输出一致）。注意力权重记为 $\mathbf{W}^{(\ell)} \in \mathbb{R}^{H \times S}$ 的最后一行（query 在末 token），即第 h 头在全体 key 位置上的分布 $\mathbf{p}^{(\ell, h)} \in \Delta^{S-1}$ 。

R32 Phase 0: 逐层探针剖面图 N=20/benchmark




Figure 1: R32 Phase0 逐层探针剖面图

(R33-S1) **ffn_gini(l)** — 门控激活幅度的不平等度 对 $|g_\ell|$ 的分量升序排列为 $0 \leq u_1 \leq \dots \leq u_d$, 记 $S_k = \sum_{i=1}^k u_i$, $S_d = \sum_{i=1}^d u_i$ 。Gini 系数常用等价形式:

$$\text{Gini}(g_\ell) = \frac{\sum_{i=1}^d (2i - d - 1) u_i}{d S_d + \varepsilon} \in [0, 1].$$

直觉: Gini 高表示少数 gate 通道「吃掉」绝大部分门控能量 (稀疏、赢家通吃); Gini 低表示门控更接近均匀, FFN 子空间「多路同时打开」。**为何仍可能失败:** 若 gate 的尺度主要由 W_{gate} 的列尺度决定, 则跨样本的 Gini 曲线会随 benchmark 叠在一起 (R33 诊断: 浅层 std 极小), 此时 Gini 更像权重先验 而非题目内容。

(R33-S2) **ffn_act_entropy(l)** — 归一化门控分布的 Shannon 熵 令 $p_i = |g_{\ell,i}| / (\sum_j |g_{\ell,j}| + \varepsilon)$, 则

$$H_{\text{ffn}}(\ell) = - \sum_{i=1}^d p_i \log(p_i + \varepsilon).$$

直觉: 熵高=门控概率在大量中间神经元上「摊薄」, 模型似乎在并行维持多种子电路; 熵低=少数子电路主导。与 Gini 的耦合: 二者都是同一向量 g_ℓ 的函数形状统计, 往往高度共线, 难以独立提供「是否该 ETD」的新信息。

(R33-S3) **ffn_boundary_frac(l)** — 临界带比例 给定 $\varepsilon_{\text{bd}} > 0$ (实验中常取 0.5),

$$\text{boundary_frac}(\ell) = \frac{1}{d} \sum_{i=1}^d \mathbb{1}\{|g_{\ell,i}| < \varepsilon_{\text{bd}}\}.$$

直觉: 若大量神经元落在 SiLU 的近似线性区附近, 微小扰动 (包括 ETD 第二步) 更容易推动神经元穿越阈值, 产生「相变」SiLU 与权重尺度使得绝大多数通道远离 0, 该比例长期贴近 1, 失去动态范围。

(R33-S4) **ffn_active_frac(l)** — 强激活比例

$$\text{active_frac}(\ell) = \frac{1}{d} \sum_{i=1}^d \mathbb{1}\{|g_{\ell,i}| > \tau_{\text{act}}\}.$$

直觉: 粗粒度「多少路 FFN 被打开」。与 boundary_frac 类似, 易受全局尺度影响。

(R33-S5) **attn_spectral_gap(l)** — 注意力「主峰 / 次峰」比 (多头的平均) 对最后一 query 位置, 第 h 头在序列维上的权重降序为 $w^{(1)} \geq w^{(2)} \geq \dots$, 定义

$$\text{gap}^{(\ell,h)} = \frac{w^{(1)}}{w^{(2)} + \varepsilon}, \quad \text{attn_spectral_gap}(\ell) = \frac{1}{H} \sum_{h=1}^H \text{gap}^{(\ell,h)}.$$

直觉: 类比幂迭代中主特征值相对次特征值的占优程度; gap 大表示注意力几乎只钉在少数 token 上, 上下文读取「单井」早期层 BOS / 特殊 token 的 sink 效应使 $w^{(2)}$ 极小, gap 在浅层被人为抬高; 进入 T-block 后比值坍塌, 信号失去层分辨率。

(R33-S6) **attn_head_consensus(l)** — 多头分布与混合分布的接近程度 设 $\mathbf{p}^{(\ell,h)}$ 为第 h 头在末 token 上的注意力分布，混合分布 $\bar{\mathbf{p}}^{(\ell)} = \frac{1}{H} \sum_h \mathbf{p}^{(\ell,h)}$ 。用对称 KL 构造多头间与混合体的平均散度，再映射为「共识」分数（实 `signal_funcs` 一致，取值高表示多头更一致）。

直觉：多头若严重分歧，说明模型在「看哪里」上尚未收敛；若高度一致，则上下文读取已形成强主方向。**局限：**共识高也可能是全体头一起错盯 sink，不等于任务上有益的注意力。

(R33-S7) **attn_top2_mass(l)** — 前两名的质量占比

$$\text{top2_mass}(\ell) = \frac{1}{H} \sum_{h=1}^H \frac{w^{(1)} + w^{(2)}}{1 + \varepsilon}.$$

直觉：与 `spectral_gap` 同源，刻画注意力是否高度集中；同样易被 sink 主导。

(R33-S8) **neuron_flip_rate(l)** — 2-Pass 门控符号翻转率 记第一次与第二次 T-block 在层 ℓ 的门控为 $\mathbf{g}_{\ell}^{(1)}, \mathbf{g}_{\ell}^{(2)}$,

$$\text{flip_rate}(\ell) = \frac{1}{d} \sum_{i=1}^d \mathbb{1}\{\text{sign}(g_{\ell,i}^{(1)}) \neq \text{sign}(g_{\ell,i}^{(2)})\}.$$

直觉：这是对「相变」最直接的微观计数；若 ETD 增益来自激活拓扑翻转，该量应与 `oracle_gain` 强相关。**实验：**相关仍弱，说明翻转本身不等于 logits 改善（可能翻转发生在与答案无关的子空间）。

(R33-S9) **active_set_jaccard(l)** — 两次 pass 的强激活集合相似度 定义激活集（示例阈值） $S^{(k)} = \{i : |g_{\ell,i}^{(k)}| > \tau\}$ ，则

$$J(S^{(1)}, S^{(2)}) = \frac{|S^{(1)} \cap S^{(2)}|}{|S^{(1)} \cup S^{(2)}| + \varepsilon}.$$

直觉：Jaccard 低表示两次 pass 打开的 FFN 子通道集合大变，「计算图」被改写；高表示子结构稳定。

(R33-S10) **plasticity_score** — 「可塑 × 单井」联合标量 在选定层 t_s （常为 T-block 入口层 8）定义

$$\text{plasticity} = (1 - \text{Gini}(\mathbf{g}_{t_s})) \cdot \text{attn_spectral_gap}(t_s).$$

直觉：需要 FFN 侧仍「未锁死」（低 Gini $\rightarrow$ 高 $1 - \text{Gini}$ ），同时注意力侧已形成强吸引子（高 gap），才像「可被二次迭两个因子在数据中常负相关或共受 sink 污染，乘积不一定稳定」。

(R33-S11) **conflict_score** — 「高熵 × 多头分歧」

$$\text{conflict} = H_{\text{ffn}}(t_s) \cdot (1 - \text{consensus}(t_s)).$$

直觉：FFN 多概念并行（高熵）且多头注意力不一致时，模型内部存在未解决的竞争；ETD 理论上可提供额外「协调时间」该竞争未必映射到多选题正确率变化。

4.3 Phase 0 可视化 (N=20)

对 5 个 benchmark 提取 T-block 区间（层 8–22）内的 FFN 信号剖面：




Figure 2: R33 Phase0 FFN 激活剖面图（各 benchmark 分组）




Figure 3: R33 Phase0 Attention 谱隙分布图




Figure 4: R33 Phase0 二维信号空间散点图 (ffn_gini $\times$ attn_spectral_gap, 颜色=oracle_gain)

4.4 Phase 1 结果 (N=50/benchmark, Spearman 检验)

信号	BoolQ	ARC-C	CSQA	TruthfulQA	MMLU-HS
ffn_gini_at8	0.025	0.133	-0.140	-0.085	-0.255
ffn_act_entropy_at8	-0.013	-0.131	0.174	0.077	0.255
ffn_boundary_frac_at8	-0.023	-0.017	0.081	0.047	0.108
attn_spectral_gap_at8	-0.198	0.063	-0.085	-0.083	-0.110
attn_head_consensus_at8	0.024	-0.169	0.217	-0.070	-0.287
neuron_flip_rate	0.093	-0.058	-0.260	-0.059	-0.075
plasticity_score	-0.203	0.062	-0.082	-0.079	-0.104

全部 p 值 > 0.05 ，无统计显著性。最高 $|\rho| = 0.287$ (MMLU-HS 的 `attn_head_consensus`)，但在同一信号在其他 benchmark 上的方向相反 (TruthfulQA = -0.070)，表明这是噪声。




Figure 5: R33 Phase1 Spearman 热图

4.5 R33 核心教训

R33 失败揭示了一个深刻规律：

R33 信号	失败原因
ffn_gini	主要反映 gate_proj 权重矩阵的属性，而非输入；layer8 处 std=0.006, CV=1.7%；5 个 benchmark 曲线完全重叠
ffn_boundary_frac	SiLU 激活函数设计上就不会产生精确的零激活；值始终在 0.88–1.0 之间
attn_spectral_gap	max/2nd 比值被 BOS sink token 在 layer 5–8 的超强注意力主导；layer 8 之后几乎为 0

核心教训：静态分布形状指标（Gini、熵、spectral gap）主要反映模型架构属性，不是输入依赖的。需要**方向（directional）**和**关系（relational）**信号。

5. R34：方向与跨模块交叉交互信号

5.1 设计原则的根本转变

从 R33 的失败中提炼出四条原则：

1. 方向优先于幅度： $\cos(\mathbf{m}_l, \mathbf{m}_{\{l-1\}})$ 比 $\|\mathbf{m}_l\|$ 的 Gini 更能反映“FFN 是否收敛于特定知识方向”
2. 关系优先于单模块： $\cos(\mathbf{a}_l, \mathbf{m}_l)$ 直接测量 attention 和 FFN 在残差流中的几何关系
3. 跨层变化率优先于单层快照：ETD 关心的是“第二遍是否会产生不同结果”，这取决于信号的变化趋势
4. 有限差分 > 分布统计：直接测量“如果移除 attention 贡献，FFN 输出会怎样变化”

5.2 Qwen3 解码层子层精确结构

```

residual_1 = hidden_states                                # h_input
hidden_states = self.input_layernorm(hidden_states)
attn_out = self.self_attn(hidden_states, ...)             # a_l (attention 输出, 残差前)
hidden_states = residual_1 + attn_out                     # h_post_attn = h_input + a_l

residual_2 = hidden_states                                # = h_post_attn
hidden_states = self.post_attention_layernorm(hidden_states)
ffn_out = self.mlp(hidden_states)                         # m_l = MLP(LN2(h_input + a_l))
hidden_states = residual_2 + ffn_out                      # h_output = h_input + a_l + m_l

```

关键事实：**FFN 的输入已经包含了 attention 的贡献**（通过 $\mathbf{h_post_attn} = \mathbf{h_input} + \mathbf{a_l}$ ）。所以 attention-to-FFN 的交叉影响在每一层内部就已经存在。

5.3 R34 十二信号字典：逐条公式与直觉（按 hook 张量严格定义）

本节所有向量均取**最后一 token**。记第 ℓ 层：层输入 $\mathbf{h}_\ell^{\text{in}}$ 、注意力子层输出（残差前） $\mathbf{a}_\ell$ 、FFN 子层输出（残差前） $\mathbf{m}_\ell$ 、层输出 $\mathbf{h}_{\ell+1} = \mathbf{h}_\ell^{\text{in}} + \mathbf{a}_\ell + \mathbf{m}_\ell$ 。记 $\text{LN1}_\ell, \text{LN2}_\ell$ 为第 ℓ 层两个 LayerNorm， MLP_ℓ 为该层 MLP。

第一组：残差流「写入强度」（S1–S2） (R34-S1) **attn_write_norm**

$$\text{AWN}(\ell) = \frac{\|\mathbf{a}_\ell\|_2}{\|\mathbf{h}_\ell^{\text{in}}\|_2 + \varepsilon}.$$

直觉：把 attention 看作在 $\mathbf{h}_\ell^{\text{in}}$ 附近追加的切向量，AWN 是其**相对步长**。大：本层注意力在残差流里「写得很用力」；小：Gini 不同，这是**幅度** × **当前状态尺度归一化**，对输入更敏感。

(R34-S2) **ffn_write_norm**

$$\text{FWN}(\ell) = \frac{\|\mathbf{m}_\ell\|_2}{\|\mathbf{h}_\ell^{\text{in}}\|_2 + \varepsilon}.$$

直觉： FFN 在残差流中的相对写入强度。若 $\text{FWN} \gg \text{AWN}$ ，该层更像「知识检索/推理核」主导；若 $\text{AWN} \gg \text{FWN}$ ，更像「上下文整理」主导。

第二组：方向漂移 (S3-S5) (R34-S3) **ffn_direction_drift**

$$\text{FDD}(\ell) = 1 - \cos_{\text{sim}}(\mathbf{m}_\ell, \mathbf{m}_{\ell-1}).$$

直觉： $\mathbf{m}_\ell$ 与 $\mathbf{m}_{\ell-1}$ 共线则 $\text{FDD}=0$ ，表示 FFN 在连续层沿同一知识方向微调；FDD 大表示 FFN 输出方向「拐弯」，可能在

(R34-S4) **attn_direction_drift**

$$\text{ADD}(\ell) = 1 - \cos_{\text{sim}}(\mathbf{a}_\ell, \mathbf{a}_{\ell-1}).$$

直觉： 注意力写入方向是否跨层稳定。ADD 大：注意力在「重新寻找」上下文组合；ADD 小：已锁定到某一阅读模式。

(R34-S5) **hidden_rotation_rate**

$$\text{HRR}(\ell) = 1 - \cos_{\text{sim}}(\mathbf{h}_{\ell+1}, \mathbf{h}_\ell).$$

直觉： 残差流总方向的跨层旋转量，综合了 $\mathbf{a}_\ell$ 与 $\mathbf{m}_\ell$ 的耦合效果。ETD 关心的是：第二遍是否会让 $\mathbf{h}$ 轨迹「走另一条路」——HRR 高表示该层对轨迹几何影响大。

第三组：跨模块交叉与反事实 FFN (S6-S9) (R34-S6) **cross_cos_a_m** (核心)

$$\text{CAM}(\ell) = \cos_{\text{sim}}(\mathbf{a}_\ell, \mathbf{m}_\ell).$$

直觉： 若 $\text{CAM} > 0$ ，注意力写入与 FFN 写入 **同向强化**；若 $\text{CAM} \approx 0$ ，两者近乎正交，「各写各的」；若 $\text{CAM} < 0$ ，两者 **在残差意义上对抗**。R34/R39 的关键经验是：Qwen3 在扫参最优 T-block 内常出现稳定的负 CAM 区，可理解为「上下文记忆」与「参数化知识」仍在争执，ETD 给第二次 pass 做仲裁的空间大。

(R34-S7) **attn_ffn_balance**

$$\text{AFB}(\ell) = \frac{\|\mathbf{a}_\ell\|_2}{\|\mathbf{a}_\ell\|_2 + \|\mathbf{m}_\ell\|_2 + \varepsilon}.$$

直觉： 归一化到 $[0, 1]$ 的注意力占比（FFN 占比为 $1 - \text{AFB}$ ）。接近 $1/2$ 表示两类写入同量级，系统处于「强耦合整合区」；0 或 1 表示一方主导，另一方难以在第二次循环中翻盘。

(R34-S8) **cross_attn_to_ffn_sensitivity** (反事实一步，幅度比)

定义反事实 FFN 输出（从同一 $\mathbf{h}_\ell^{\text{in}}$ 出发，**去掉** attention 贡献，只把 LN2 作用于未加注意力的分支；实现与 hook 中额外一次 $\text{MLP}(\text{LN2}(\mathbf{h}_{\text{in}}))$ 一致）：

$$\mathbf{m}_\ell^{\text{cf}} = \text{MLP}_\ell(\text{LN2}_\ell(\mathbf{h}_\ell^{\text{in}})), \quad \mathbf{m}_\ell^{\text{act}} = \mathbf{m}_\ell = \text{MLP}_\ell(\text{LN2}_\ell(\mathbf{h}_\ell^{\text{in}} + \mathbf{a}_\ell)).$$

则

$$\text{CA2F-Sens}(\ell) = \frac{\|\mathbf{m}_\ell^{\text{act}} - \mathbf{m}_\ell^{\text{cf}}\|_2}{\|\mathbf{m}_\ell^{\text{act}}\|_2 + \varepsilon}.$$

直觉： 这是「若没有 attention，FFN 会走多远」的相对误差。大：FFN 对「是否已读入上下文」极度敏感，attention 与 FFN 强耦合；小：FFN 几乎不依赖当前 attention 读出的内容。**与 R35 的联系：** $\mathbf{m}_\ell^{\text{act}} - \mathbf{m}_\ell^{\text{cf}}$ 正是交换子向量中 **Term1** 的那一半（context→knowledge）。

(R34-S9) **cross_attn_to_ffn_direction_shift** (反事实一步, 方向版)

$$\text{CA2F-Dir}(\ell) = 1 - \cos_{\text{sim}}(\mathbf{m}_{\ell}^{\text{act}}, \mathbf{m}_{\ell}^{\text{cf}}).$$

直觉： 幅度比 (S8) 大但方向不变, 表示 attention 只「放大/缩小」已有 FFN 决策; 方向版大表示 attention **改变了 FFN 选择的子空间方向**。ETD 若改变 hidden, 第二种情况更可能翻转答案。

第四组: **logit 空间动力学与残差步长 (S10-S12)** (R34-S10) **logit_lens_jsd_vel**

记 $\mathbf{z}_{\ell} = \text{LM}(\mathbf{h}_{\ell})$ 为第 ℓ 层 logit lens 的 logits 向量, $P_{\ell} = \text{softmax}(\mathbf{z}_{\ell})$, 则

$$\text{LL-JSD-Vel}(\ell) = \text{JSD}(P_{\ell}, P_{\ell-1}).$$

直觉： 相邻层上「若立刻读出答案分布」变化有多快。高峰常出现在语义快速重排区; 与 T-block 的关系是**间接的**(经过 LM 头非线性), 但在 R29/R30 中表现出较强的 benchmark 级相关性。

(R34-S11) **prediction_flip_rate**

$$\text{PFR}(\ell) = \mathbb{1}\{\arg\max(\mathbf{z}_{\ell}) \neq \arg\max(\mathbf{z}_{\ell-1})\} \quad (\text{按层布尔, 聚合时取样本均值}).$$

直觉： 中层 top-1 类标签是否频繁翻转。高: logit lens 视角下「决策边界」附近, 微小扰动 (含 ETD) 更易改变预测。

(R34-S12) **residual_write_norm**

$$\text{RWN}(\ell) = \frac{\|\mathbf{h}_{\ell+1} - \mathbf{h}_{\ell}\|_2}{\|\mathbf{h}_{\ell}\|_2 + \varepsilon} = \frac{\|\mathbf{a}_{\ell} + \mathbf{m}_{\ell}\|_2}{\|\mathbf{h}_{\ell}\|_2 + \varepsilon}.$$

直觉： 该层在残差流上的 **相对总步长**。大: 本层整体更新剧烈; 小: 接近恒等。与 R39 的 `delta_h_ratio` 思想同源。


5.4 实验结果与图表

对 8 个 benchmark (N=20 each) 提取全部 12 个信号的逐层曲线, 以下为部分代表性结果:


BoolQ (T-block [8, 22]) 的关键信号剖面 (取自 `r34_cross_memory_stats.json`):

信号	L9 均值	L18 均值	L27 均值	趋势特征
<code>attn_write_norm</code>	0.181	0.188	0.101	中层略高, 深层下降
<code>ffn_write_norm</code>	0.526	0.341	0.261	随深度单调递减
<code>attn_ffn_balance</code>	0.256	0.356	0.278	中层最平衡 (峰值在 L18)
<code>cross_cos_a_m</code>	-0.093	-0.217	0.021	T-block 内为负值 (对抗竞争), 深层变正
<code>cross_attn_to_ffn_sens</code>	0.391	0.679	0.231	T-block 中后期峰值
<code>ffn_direction_drift</code>	1.153	0.955	0.824	随深度下降 (FFN 方向逐渐收敛)


关键发现: `cross_cos_a_m` (attention 与 FFN 输出的余弦相似度) 在 T-block 内呈现明显的负值 (-0.093 到 -0.217), 表明两者处于方向竞争状态, 而在 T-block 之后转为正值。这是**第一个与 T-block 区间有明确几何对应关系的信号**。各 benchmark 的逐层信号剖面图:




• BoolQ:



• ARC-C:



• TruthfulQA:



• GPQA-Diamond:

全 benchmark 叠加对比图:

5.5 R34 核心发现

$\text{cross_cos_a_m} = \cos(a_l, m_l)$ 在 Qwen3-8B 上展示出一个重要特征: **T-block 区间内, attention 输出 a_l 与 FFN 输出 m_l 方向对抗 (负值)**, 而 **T-block 之后方向协同 (正值)**。这一几何结构与 T-block 的功能高度对应: 中间层的 ETD 之所以有效, 正是因为这里存在“注意力上下文”与“FFN 长期记忆”之间的协调竞争, 而 ETD 的第二次迭代恰好提供了再次协调的机会。




Figure 6: R34 全 Benchmark 叠图

6. R35: Attention-FFN 非对易交换子实验

6.1 动机：从一阶观测到二阶对象

R34 的 12 个信号全部是状态空间的一阶观测——它们度量的是 a_l, m_l, h_l 本身的统计性质（范数、方向、余弦等）。但 ETD 第二遍的真正增益来自一个二阶对象：Attention 和 FFN 作为算子的非对易程度。

R34 的 $\text{cross_attn_to_ffn_sensitivity}$ ($\|MLP(LN(h+a)) - MLP(LN(h))\|$) 实际上已经在计算交换子的一半 (con to-knowledge 方向的精确有限差分)，但它只取了范数且完全缺失了另一半 (knowledge-to-context)，更没有考虑两项

6.2 数学框架：层级精确交换子

对 Qwen3-8B 的 Pre-LN 结构，记：- $\tilde{a}_l(h') = \text{SelfAttn}(\text{LN1}(h'))$: attention 子层函数 - $\tilde{m}_l(h') = \text{MLP}(\text{LN2}(h'))$: FFN 子层函数 - $A_l(h) = h + \tilde{a}_l(h)$, $M_l(h) = h + \tilde{m}_l(h)$: 含残差的映射

标准顺序 (Attention first) : $M_l \circ A_l(h) = h + \tilde{a}_l(h) + \tilde{m}_l(h + \tilde{a}_l(h))$

反转顺序 (MLP first) : $A_l \circ M_l(h) = h + \tilde{m}_l(h) + \tilde{a}_l(h + \tilde{m}_l(h))$

精确交换子：

$$C_l(h) = M_l(A_l(h)) - A_l(M_l(h)) = \underbrace{[\tilde{m}_l(h + \tilde{a}_l(h)) - \tilde{m}_l(h)]}_{\text{Term1: context} \rightarrow \text{knowledge}} + \underbrace{[\tilde{a}_l(h) - \tilde{a}_l(h + \tilde{m}_l(h))]}_{\text{Term2: knowledge} \rightarrow \text{context (全新)}}$$

Term1 正是 R34 的 $\text{cross_attn_to_ffn_sensitivity}$ 所计算的差向量。**Term2** 是全新的：它度量“FFN 当前写入的知识方向会不会改变 Attention 的上下文检索模式”——这在之前从未被计算过。

6.3 R35 信号字典：交换子向量及其范数、分解与方向余弦

以下均在第 ℓ 层、最后一 token 的向量上计算。记该 token 上标准前向已得到的 $\mathbf{h} = \mathbf{h}_\ell^{\text{in}}$ (与 R35 实现一致：在 pre-attn 状态上构造交换子)。定义两项 (与 § 6.2 记号一致)：

$$\mathbf{T}_\ell^{(1)} = \tilde{\mathbf{m}}_\ell(\mathbf{h} + \tilde{\mathbf{a}}_\ell(\mathbf{h})) - \tilde{\mathbf{m}}_\ell(\mathbf{h}), \quad \mathbf{T}_\ell^{(2)} = \tilde{\mathbf{a}}_\ell(\mathbf{h}) - \tilde{\mathbf{a}}_\ell(\mathbf{h} + \tilde{\mathbf{m}}_\ell^0),$$

其中 $\tilde{\mathbf{m}}_\ell^0 = \text{MLP}_\ell(\text{LN2}_\ell(\mathbf{h}))$ 表示未加 attention 分支时的 FFN 输出 (与 R34 Term1 反事实同构)。精确交换子向量为

$$\mathbf{C}_\ell = \mathbf{T}_\ell^{(1)} + \mathbf{T}_\ell^{(2)} \in \mathbb{R}^d.$$

层残差总增量（与 hook 一致） $\Delta \mathbf{h}_\ell = \mathbf{h}_{\ell+1} - \mathbf{h}_\ell^{\text{in}} = \mathbf{a}_\ell + \mathbf{m}_\ell$ （此处 $\mathbf{a}_\ell, \mathbf{m}_\ell$ 为标准顺序下的子层输出）。

(R35-S1) **commutator_norm**

$$\text{CN}_\ell = \|\mathbf{C}_\ell\|_2.$$

直觉： 顺序交换 $A \circ M$ 与 $M \circ A$ 造成的「几何差向量」长度。大表示 attention 与 FFN 在该层强非对易。**陷阱：** 在 Pre-LN 下 $\|\mathbf{a}_\ell\|, \|\mathbf{m}_\ell\|$ 常随 ℓ 增大, $\|\mathbf{C}_\ell\|$ 往往随深度单调上升, 与「哪一段最值得 ETD」脱钩（R36 专门解决此混淆）。

(R35-S2) **commutator_norm_rel**

$$\text{CN-rel}_\ell = \frac{\|\mathbf{C}_\ell\|_2}{\|\Delta \mathbf{h}_\ell\|_2 + \varepsilon}.$$

直觉： 交换子占「本层实际写入残差流」的比例。若交换子很大但残差写入更大, 说明非对易性相对整体更新仍只是一部分。

(R35-S3) **term1_norm (context $\rightarrow$ knowledge)**

$$\text{T1N}_\ell = \|\mathbf{T}_\ell^{(1)}\|_2.$$

直觉： 只把 attention 当作对 FFN 输入的扰动时, FFN 输出改变多少。即 R34 `cross_attn_to_ffn_sensitivity` 的分子向量的范数。

(R35-S4) **term2_norm (knowledge $\rightarrow$ context)**

$$\text{T2N}_\ell = \|\mathbf{T}_\ell^{(2)}\|_2.$$

直觉： FFN 先写一笔后, attention 的读出模式改变了多少。R34 **完全没有**这一半; 它解释「为何仅有 Term1 范数不够」。

(R35-S5) **term_ratio**

$$\text{TR}_\ell = \frac{\text{T1N}_\ell}{\text{T1N}_\ell + \text{T2N}_\ell + \varepsilon} \in [0, 1].$$

直觉： 在该层非对易性中, 哪一支路主导: 接近 1 表示 context $\rightarrow$ knowledge 通道主导; 接近 0 表示 knowledge $\rightarrow$ context 主导; 约 0.5 表示两支路同量级。

(R35-S6) **cancellation_ratio**

$$\text{CR}_\ell = \frac{\|\mathbf{C}_\ell\|_2}{\text{T1N}_\ell + \text{T2N}_\ell + \varepsilon}.$$

直觉： 若 $\mathbf{T}_\ell^{(1)}$ 与 $\mathbf{T}_\ell^{(2)}$ 反向, 则 $\|\mathbf{C}_\ell\| \ll \text{T1N} + \text{T2N}$, CR_ℓ 变小 (强对消); 若两者同向叠加, CR_ℓ 接近 1。BoolQ T-block 上均值约 0.69, 说明存在 **稳定的部分对消**。

(R35-S7) **commutator_cos_with_residual** (即 R37-R38 的 **cos_res** 几何原型之一)

$$CCR_{\ell} = \cos_sim(C_{\ell}, \Delta h_{\ell}).$$

直觉： 交换子向量是否落在「本层真实更新方向」附近。高：顺序差异与**最终写入一致**；低：交换子与真实残差更新近乎正 logits 的「有效投影」可能更弱。后续 R37 将 **Term1** 与 Δh 的余弦单独用作 **cos_res** 选窗标量。

(R35 Phase-1 扩展) 方向级分解 (统计文件中的 **cos_***)

$$CTT_{\ell} = \cos_sim(T_{\ell}^{(1)}, T_{\ell}^{(2)}), \quad CCA_{\ell} = \cos_sim(C_{\ell}, a_{\ell}), \quad CCM_{\ell} = \cos_sim(C_{\ell}, m_{\ell}).$$

直觉： $CTT_{\ell} < 0$: 两支路 **互相抵消** 一部分，解释了「范数大但有效非对易未必大」。 CCA_{ℓ}, CCM_{ℓ} 描述交换子更贴近 **读上下文** 还是 **写知识** 的子空间。

6.4 BoolQ 实验数据 (N=20)


从 r35_commutator_stats.json 中提取的关键统计量：


指标	Layer 9	Layer 18	Layer 27	T-block 均值
commutator_norm	10.55	17.44	25.14	14.41
commutator_norm_rel	0.454	0.679	0.301	0.565
term1_norm	8.84	16.92	17.91	12.53
term2_norm	6.54	8.85	17.24	8.32
term_ratio (Term1占比)	0.575	0.656	0.508	0.599
cancellation_ratio	0.686	0.677	0.715	0.690
cos(C_l, Δh_l)	0.278	0.423	0.062	0.283
cos(Term1, Term2)	-0.086	-0.204	0.018	-0.099
cos(C_l, a_l)	-0.164	-0.295	-0.111	-0.191
cos(C_l, m_l)	0.341	0.600	0.112	—

关键发现：

1. **commutator_norm** 随深度单调增长 (L9: 10.55 $\rightarrow$ L27: 25.14)，**与 T-block 不对齐**
2. $\cos(\text{Term1}, \text{Term2}) \approx -0.099$ (T-block 均值)，两项方向**持续对消约 30%**
3. $\text{cancellation_ratio} \approx 0.69$ (< 1)，证实了方向对消现象
4. $\cos(C_l, a_l) \approx -0.191$ ，交换子方向偏离 attention 写入方向

各 benchmark 的交换子剖面图：





全 benchmark 叠图（展示 commutator_norm 无法区分 T-block 的失败）：




Figure 7: R35 全 Benchmark 叠图

R35 vs R34 对比图（交换子信号与交叉信号的直接对比）：

6.5 R35 核心教训

绝对 norm 路线的失败根因：

$\|C_L\| \propto \|\tilde{a}_L\| \cdot \|m_{\square}_L\|$ ，而 Pre-LN 架构的残差流 norm 随深度单调增长，交换子 norm 本质上是深度的函数，而不是 T-block 的函数。




Figure 8: R35 vs R34 全面对比

但 R35 有一个重要的正面发现：Term1 (context $\rightarrow$ knowledge) 与 Term2 (knowledge $\rightarrow$ context) 在 T-block 内部存在稳定的方向对消 ($\cos(T1, T2) \approx -0.1$)，这意味着两项并非独立的。这种对消结构可能正是 ETD 第二遍“整合”作用的几何体现。

7. R36：方向特异性传播增益实验

7.1 问题诊断：绝对 norm 与 T-block 完全不对齐

R35 确认了交换子向量确实存在，但绝对 norm $\|C_L\|$ 在后期层 (28-35) 反而最高，与 T-block 完全不对齐。失败根源在于 Pre-LN 架构中残差流 norm 随深度增长的系统性混淆。

7.2 用户提出的关键洞见

ETD 不是找“最剧烈的层”，而是找“最值得再协调一次的层”。

这产生两个必须同时满足的条件：

1. 方向对齐：当前层的顺序差异落在实际写入方向附近 ($\cos(C_L, \Delta h_L)$ ，已有 R35 commutator_cos_with_residual)
2. 传播特异性：这种差异经过后续层后，比随机方向更能特异性地影响最终预测

7.3 核心数学框架：logits 上的扰动、随机对照与复合标量

R36 在不训练、不扫全层 Jacobian 的前提下，用「一次额外前向」近似回答：若只在第 ℓ 层入口把隐藏状态沿某方向微推与随机方向对比，可剔除「越深 logits 越敏感」的伪信号。

记完整模型 (除 T-block 细节外) 为 $\mathcal{M}$ 。对样本 x ，在探针层 $\ell \in \mathcal{P}$ (实现中 $\mathcal{P} = \{3, 6, \dots, 33\}$) 上，用 register_forward_pre_hook 在 model.model.layers[ℓ] 的输入张量第一分量上加扰动 (与 exp_r36 一致)：仅对最后一 token 位置的隐藏向量加 $\varepsilon \hat{v}$ ，其余 token 不变。记扰动后末 token logits 为 $\mathbf{z}^{(\ell)}(\hat{v}) \in \mathbb{R}^{|\mathcal{V}|}$ ，无扰动为 $\mathbf{z}^{(\ell)}(0)$ 。定义分布 $P = \text{softmax}(\mathbf{z}^{(\ell)}(0))$ ， $Q(\hat{v}) = \text{softmax}(\mathbf{z}^{(\ell)}(\hat{v}))$ 。

(R36-S1) **prop_sens**：沿交换子单位方向的传播灵敏度 取 $\hat{C}_\ell = C_\ell / (\|C_\ell\|_2 + \varepsilon)$ (与 §6.3 的 C_ℓ 相同)， $\varepsilon_{\text{inj}} > 0$ (实现常取 1.0)，则

$$\text{PropSens}_\ell(x) = \text{JSD}(P, Q(\hat{C}_\ell)).$$

直觉：问「沿真实非对易方向推一下，答案分布变不变」。大：该方向经 Decoder 放大后仍显著改变输出；小：很快在非

(R36-S2) **rand_sens**: 随机单位方向对照 $\hat{\mathbf{r}}$ 为与 $\mathbf{C}_\ell$ 同维、从球面均匀采样（每样本每层独立），则

$$\text{RandSens}_\ell(x) = \text{JSD}(P, Q(\hat{\mathbf{r}})).$$

直觉：任何方向在后期层都可能把 logits 推得很响；仅用 PropSens 会把「深层的普遍敏感」误认为「交换子特别重要」。

(R36-S3) **directional_advantage**: 方向特异性增益

$$\text{DA}_\ell(x) = \frac{\text{PropSens}_\ell(x)}{\text{RandSens}_\ell(x) + \varepsilon}.$$

判读： $\text{DA}_\ell > 1$ ： $\mathbf{C}_\ell$ 方向对输出的影响强于典型随机方向 $\rightarrow$ 交换子携带的「结构化信息」在传播中幸存； $\text{DA}_\ell \approx 1$ ：与随机扰动无异 $\rightarrow$ 后期层虽 PropSens 大但比值塌缩（R36「后期层悖论」）。注意：该比值在样本间方差极大，报告均值与中位数。

(R36-S4) **etd_effective**: 对齐 $\times$ 特异性

$$\text{Eff}_\ell(x) = \text{CCR}_\ell \cdot \text{DA}_\ell(x) = \cos_{\text{sim}}(\mathbf{C}_\ell, \Delta \mathbf{h}_\ell) \cdot \text{DA}_\ell(x).$$

直觉：同时要求 (i) 交换子与真实层写入同向（CCR 大），(ii) 该方向在 logits 上比随机更特殊（DA 大）。缺一：要么「响但不准」，要么「准但不响」。

(R36-S5) **comm_persist**: 相邻层交换子方向持续性（无额外前向）

$$\text{CPersist}_\ell = \cos_{\text{sim}}(\mathbf{C}_\ell, \mathbf{C}_{\ell+1}).$$

（实现里第 0 层或首层可能记为 NaN，与 JSON 一致。）

直觉：若相邻层交换子方向一致，说明非对易性的「模式」在深度上延续，该区域更像一块连贯的「协调未竟」区；若符号 R39 假设 H4 的联系：作为不依赖 Term1 反事实、也不依赖双 LN 拆分的量，被提出作跨架构候选。

Hook 注入与 RoPE 的说明（实现直觉） 直接在 `layers[l]` 前对 hidden states 加扰动，可利用模型已有 position embedding/cache 路径，避免手写 RoPE 重放。代价：每探针层、每个扰动方向各需一整次前向；故 R36 只在稀疏集合 $\mathcal{P}$ 上评测。

7.4 探针层实验（Qwen3-8B, N=100）


探针层：[3, 6, 9, 12, 15, 18, 21, 24, 27, 30, 33]（11 层，间隔 3）


BoolQ 的关键传播指标（取自 `r36_propagation_stats.json`）：

指标	T-block 均值	后期层（L27-L33）均值
<code>directional_advantage</code>	3.725	5.906
<code>directional_advantage</code> （中位数）	0.987	0.981
<code>prop_sens</code>	2.40×10^4	1.51×10^4
<code>rand_sens</code>	2.37×10^4	1.63×10^4

关键观察：`directional_advantage` 的均值在后期层更高（ $5.91 > 3.73$ ），但中位数在 T-block 内更高（ $0.987 > 0.981$ ），说明后期层的高均值是由少数异常值（大方差）驱动的，不是稳定信号。

各 benchmark 传播剖面图：





全 benchmark 叠图：

个体样本方差图（展示样本间 directional_advantage 差异）：

个体样本曲线（5 个代表性样本的 directional_advantage 轨迹）：




Figure 9: R36 全 Benchmark 叠图





Figure 10: R36 样本方差图



后期层悖论图（prop_sens vs directional_advantage 的分离）：




Figure 11: R36 后期层悖论

directional_advantage vs ETD 增益散点图（H3 检验）：

7.5 R36 核心发现：cos(a_l, m_l) 是意外的候选信号

虽然 directional_advantage 未能精确定位 T-block，但 R36 实验的副产品——从 R34 沿用的 **cos(a_l, m_l)** (**cross_cos_a_m**) 信号——在 Qwen3-8B 的所有 8 个 benchmark 上均呈现出一致的“T-block 内为负值”结构，且不同 benchmark 的**竞争区起点**（cos 由正转负的层）与各自的最优 t_start 有一定对应关系。这为后续 R37–R39 的选窗方法提供了理论基础。




Figure 12: R36 DA vs Delta 散点图

8. R37：信号引导 ETD 选层（过渡实验）

8.1 实验设计

R37 将 $\cos(a_l, m_l)$ (cross_cos_a_m) 的信号——更确切地说，其变换版 $\cos_res = \cos(\text{Term1}, \Delta h_l)$ ——作为选窗信号，在 MMLU-HS-Math、GPQA-Diamond、AGIEval 三个硬推理 benchmark 上验证多种选窗策略 (N=100/

条件	选窗方式
baseline	无 ETD
oracle (sweep_best)	扫参最优固定窗口
global_cos6/8	全局 $\cos_res$ 均值最高的 6/8 层窗口
persample_cos6/8/10	逐样本 $\cos_res$ 滑动窗口, $n_t=6/8/10$
persample_variable	逐样本 $n_t \in \{4, 6, 8\}$ 全搜索
onset_cos8	固定阈值 0.28 onset, $n_t=8$

8.1b R37 使用的剖面信号： $\cos_res$ 的精确定义与选窗直觉

R37 在实现里使用的 $\cos_res$ 不是原始的 $\text{CAM}_\ell = \cos_sim(a_\ell, m_\ell)$ ，而是 **Term1**（反事实 FFN 差分）与层残差总增量之间的余弦，与 R35 中 $T_\ell^{(1)}$ 及 Δh_ℓ 对齐：

$$T_\ell^{(1)} = \text{MLP}_\ell(\text{LN2}_\ell(h_\ell^{\text{in}} + a_\ell)) - \text{MLP}_\ell(\text{LN2}_\ell(h_\ell^{\text{in}})), \quad \Delta h_\ell = a_\ell + m_\ell, \\ \cos_res(\ell) = \cos_sim(T_\ell^{(1)}, \Delta h_\ell).$$

直觉： $T_\ell^{(1)}$ 回答「attention 通过改变 FFN 输入，把 FFN 输出推离了多少」； Δh_ℓ 是「本层最终写进残差流的总增量」。FFN 修正与「注意力+FFN 合写」在同一几何象限里，ETD 再跑一遍 T-block 更像在沿已对齐的合力方向继续加工；二者近根因）：该量依赖 $\text{LN2}(h^{\text{in}} + a)$ 与 $\text{LN2}(h^{\text{in}})$ 的拆分方式，在 Gemma2 双 LN 上物理意义被削弱。

与 R39 neg_cos_am 的关系：R39C 选窗主要用 $-\text{CAM}_\ell$ （竞争区： $\text{CAM}_\ell \ll 0$ 时 $-\text{CAM}_\ell$ 大），无需额外反事实 MLP，但回答的是略不同的问题——「两子层写入是否对抗」而非「Term1 与总增量是否对齐」。

选窗操作（抽象模板，与 R37/R38 代码同构）：对每层得标量 s_ℓ （此处 $s_\ell = \cos_res(\ell)$ 或其单调变换）。滑动窗：在合法 (n_e, n_t) 上最大化 $\sum_{\ell=n_e}^{n_e+n_t-1} s_\ell$ 。onset：找最小 ℓ^* 使 $s_{\ell^*} \geq \tau$ 且 $\ell^* \in [L_{\min}, L_{\max}]$ ，再取固定宽度窗口 $[\ell^*, \ell^* + n_t - 1]$ 。R37 的 onset_cos8 即 $\tau=0.28$, $n_t=8$ 。

8.2 R37 关键结果 (MMLU-HS-Math)

条件	Accuracy	Δ vs Baseline
baseline	0.400	0.000
oracle (sweep_best)	0.430	+0.030
global_cos6	0.370	-0.030
global_cos8	0.410	+0.010
persample_cos6	0.410	+0.010
persample_cos8	0.370	-0.030
persample_cos10	0.400	0.000
persample_variable	0.370	-0.030
onset_cos8	0.430	+0.030 (= oracle)

onset_cos8 在 MMLU-HS-Math 上达到了与 sweep_best 完全相同的准确率，是 R37 的核心发现。

9. R38：全 Benchmark 信号优化实验

9.1 实验设计

R38 将 R37 的方法扩展至全部 8 个 benchmark，引入“标定阶段” (N_CALIB=20 样本)，以解决跨 benchmark 的阈值适配问题，并将 oracle 命名改为 sweep_best。7 个实验条件：

条件	说明
baseline	无 ETD
sweep_best	扫参最优固定窗口
persample_cos8	逐样本 cos_res 滑动窗口, n_t=8
persample_variable	逐样本 n_t ∈ {4,6,8} 全搜索
onset_fixed8	固定阈值 0.28 onset, n_t=8 (R37 MMLU 赢家)
calib_onset8	自适应阈值 onset, n_t=8 (新)
calib_global8	标定均值最优全局窗口, n_t=8 (新)

9.1b 标定阶段 (Calibration) 的数学定义

R38 对若干 benchmark 在前 N_{calib} (常取 20) 条样本上只做 **probe 前向** (无 ETD), 得到每层标量剖面 $s_\ell^{(i)}$ (在 R38a 中 $s_\ell = \text{cos_res}(\ell)$ 与 R37 同构)。定义 **标定均值剖面**:

$$\bar{s}_\ell = \frac{1}{N_{\text{calib}}} \sum_{i=1}^{N_{\text{calib}}} s_\ell^{(i)}.$$

calib_global8: 在所有满足 $n_t = 8$ 且 $n_e \in [L_{\min}, L_{\max}]$ 的窗口 $\mathcal{W} = [n_e, n_e + 7]$ 上, 最大化窗口内均值和 $\sum_{\ell \in \mathcal{W}} \bar{s}_\ell$, 输出 $\arg \max$ 对应窗口 (实现与 `derive_global_window_from_profile` 一致)。

calib_onset8 (自适应阈值 onset): 先在中间层区间 $\ell \in [9, 22]$ (与计划一致) 取 $M = \max_\ell \bar{s}_\ell$, 设阈值 $\tau = \rho \cdot M$ (R38 计划取 $\rho = 0.65$)。从 $\ell = L_{\min}$ 向右扫描, 第一个满足 $\bar{s}_\ell \geq \tau$ 的层记为 ℓ^* , 窗口取 $[\ell^*, \ell^* + 7]$ 。这样 **阈值随 benchmark 自动缩放**, 避免 R37 onset_fixed8 的 $\tau = 0.28$ 在部分任务上整体失效。

onset_fixed8: 与 R37 相同, $\tau = 0.28$ 固定, 不读标定统计量; 用于对照「标定是否必要」。

persample_cos8 / persample_variable: 对每个评测样本 i 单独用其 $s_\ell^{(i)}$ 做滑动窗或 $\{4, 6, 8\}$ 宽度搜索; 标定不进入该分支, 成本更高但灵活性最大。

9.2 R38 完整实验结果 (8 Benchmark $\times$ 7 条件)

Benchmark	baseline	sweep_best	persample_cos8	persample_variable	onset_fixed8	calib_onset8	calib_global8
BoolQ	0.820	0.870	0.820	0.840	0.820	0.820	0.830
ARC-C	0.560	0.580	0.540	0.550	0.510	0.520	0.560
TruthfulQA	0.320	0.380	0.300	0.360	0.340	0.320	0.300
CSQA	0.640	0.690	0.680	0.620	0.630	0.620	0.670
MMLU- HS-Math	0.400	0.430	0.370	0.370	0.430	0.450	0.370
GPQA- Diamond	0.380	0.440	0.400	0.370	0.360	0.360	0.390
AGIEval- Gaokao- MathQA	0.520	0.540	0.500	0.580	0.470	0.520	0.480
(LogiQA)	0.360	0.500	–	–	–	–	–

9.3 R38 核心结论

R38 的关键结论是: **cos_res 信号 (cos(Term1, Δh_l)) 在 Qwen3-8B 上有弱效果, 但始终无法超越 sweep_best**。calib_onset8 在 MMLU-HS-Math 上以 0.450 超过了 sweep_best (0.430), 这是信号引导方法在 8 个 benchmark 中唯一一次超越 sweep_best 的情况。其余 benchmark 均不如 sweep_best, 且部分条件 (如 persample_cos8 在 ARC-C、TruthfulQA 上) 反而低于 baseline。




Figure 13: R38 全 Benchmark 各条件条形图




Figure 14: R38 热力图 (Δ acc 相对 baseline)




Figure 15: R38 标定剖面图（8 个 benchmark 的 mean cos_res 曲线）

10. R39：跨架构 ETD 根因分析与信号筛选

10.1 背景：向 Llama3-8B 和 Gemma2-2B 扩展时的失败

R38 之后，将 cos_res 信号应用到 Llama3-8B 和 Gemma2-2B 时，信号完全失效。R39 进行了系统性的根因分析。

10.2 三架构信号诊断

模型	cos_res 范围	正值层比例	信号区分 sweep_win 的 benchmark 数	峰值层规律
Qwen3-8B	0.07 ~ 0.56	12/12 全正	3/8 (GPQA+0.145, TruthfulQA+0.121, BoolQ+0.064)	早期 L6-L8 假阳性 + 中后期有效结构
Llama3-8B	-0.35 ~ 0.28	约 7/11	4/8 (但幅度极低, diff<0.13)	所有任务峰值均锁定在 L10
Gemma2-2B	-0.37 ~ 0.38	约 4/10	2/8, 5/8 为负区分	固定正峰在 L18-L20, L6-L16 全为负值

三个根因：

- **根因 A (Qwen3)**：Qwen3 的 cos_res 全中间层均为正值，这可能是 Qwen3 特有的权重初始化或训练结果，而非 Transformer 层动力学的普适性质。
- **根因 B (Llama3)**：Llama3 的 cos_res 在所有 8 个任务中峰值均在 L10，与任务完全无关。而 sweep_best 窗口极度分散 (MMLU [13,15]、AGIEval [20,22]、BoolQ [9,15])，信号与 ETD 有效区间的方向完全脱节。
- **根因 C (Gemma2)**：Gemma2 使用 pre_feedforward_layernorm + post_feedforward_layernorm 双重归一化，Term1 的近似 $(\text{mlp}(\text{pre_ffn_norm}(h_i)) - m_l_actual)$ 在双 LN 架构下会对缺少 attention 更新的向量归一化，导致 cos_res 在 L6-L16 大面积为负，而 sweep_best 窗口恰好有 5/8 落在这个负值区。

10.3 R39 六路候选信号字典：公式、代价与直觉

R39A 的筛选思想是：对每个 (模型, benchmark)，比较 sweep_best 窗口内与窗口外的信号均值差 (disc_score)、覆盖 t_{start} 对齐误差等；本节只给出 **每条信号的可计算定义** 与 **为何可能被选作选窗 proxy**。

(R39-S1) **cos_res** (与 § 8.1b 相同, 再写一遍便于对照)

$$\text{cos_res}(\ell) = \text{cos_sim}(\mathbf{T}_\ell^{(1)}, \mathbf{a}_\ell + \mathbf{m}_\ell).$$

计算代价: 每层一次额外 MLP(LN2($\mathbf{h}^{\text{in}}$)) (反事实分支)。

直觉: 「上下文对 FFN 的偏转」是否与「本层最终写入」一致。

失效模式: Llama 峰值锁 L10; Gemma2 双 LN 下 $\mathbf{T}^{(1)}$ 定义失真。

(R39-S2) **cos_am** (即 R34 CAM_ℓ ; R39C 用其 负值区 做 **neg_cos_am_calib**)

$$\text{cos_am}(\ell) = \text{cos_sim}(\mathbf{a}_\ell, \mathbf{m}_\ell).$$

计算代价: 仅 hook, 已算 $\mathbf{a}_\ell, \mathbf{m}_\ell$ 时 $O(d)$ 。

直觉: $\text{cos_am} \ll 0$: 读与写在残差几何上 **对抗** (竞争未平), ETD 第二次循环像强行再开一轮「仲裁」; $\text{cos_am} \gg 0$: 两者合力, 再循环边际收益小。R39C 的 **neg_cos_am_calib**: 在标定集上构造 $\bar{s}_\ell = -\overline{\text{cos_am}}_\ell$ (或对每样本再平均), § 9.1b 类 **global / onset** 规则取 n_t 固定窗。

(R39-S3) **comm_persist** (相邻层交换子余弦; 索引方向以脚本为准) R36 正文写 $\text{cos_sim}(\mathbf{C}_\ell, \mathbf{C}_{\ell+1})$ (向前看一层); 计划文档写 $\text{cos}(\mathbf{C}_\ell, \mathbf{C}_{\ell-1})$ (向后看一层)。二者只差 **重标号**, 本质都是 **度量交换子方向沿深度是否平滑**。下文统一记为

$$\text{comm_persist}(\ell) = \text{cos_sim}(\mathbf{C}_\ell, \mathbf{C}_{\ell\pm 1}).$$

计算代价: R35 已算 $\mathbf{C}_\ell$, 相邻层余弦 **无额外前向**。

直觉: 非对易性是否在深度方向 **连贯积累**; 高值区可能对应「一整段尚未完成 attention-FFN 协调」的层带。

(R39-S4) **delta_h_ratio**

$$\text{delta_h_ratio}(\ell) = \frac{\|\mathbf{a}_\ell + \mathbf{m}_\ell\|_2}{\|\mathbf{h}_\ell^{\text{in}}\|_2 + \varepsilon}.$$

计算代价: 范数与除法, 可并入同一 probe。

直觉: 该层对残差流的 **相对步长**; 大步长层若算错代价高, 可能更值得「再算一遍」。与 R34 **residual_write_norm** 同型。

(R39-S5) **attn_entropy** 对末 token、第 ℓ 层、第 h 头注意力分布 $\mathbf{p}^{(\ell, h)} \in \Delta^{S-1}$,

$$H_{\text{attn}}(\ell) = \frac{1}{H} \sum_{h=1}^H \left(- \sum_{j=1}^S p_j^{(\ell, h)} \log(p_j^{(\ell, h)} + \varepsilon) \right).$$

计算代价: 需 eager attention 权重或等价中间量。

直觉: 高熵: 模型仍「四处张望」; 低熵: 已强聚焦。是否与 ETD 增益单调相关 **依赖任务**: 长上下文 BoolQ 与短题 TruthfulQA 模式不同。

(R39-S6) **empirical_logit_gain** (R39C: **emp_logit_fixed**的理论对象) 对候选窗口 $\mathcal{W}$, 在标定子集上运行真实 ETD ($k=2$), 对每个样本、正确答案类别 y^* 记录

$$g_{\mathcal{W}}^{(i)} = \log p_{i,y^*}^{(\text{ETD})} - \log p_{i,y^*}^{(\text{base})}, \quad \widehat{G}(\mathcal{W}) = \frac{1}{N_{\text{calib}}} \sum_i g_{\mathcal{W}}^{(i)}.$$

选 $\mathcal{W}^* = \arg \max_{\mathcal{W} \in \mathcal{C}} \widehat{G}(\mathcal{W})$, 其中 $\mathcal{C}$ 为小候选集 (8-12 个窗口, stride 与 R39 计划一致), 再在评测集上固定使用 $\mathcal{W}^*$ 。

计算代价: $|\mathcal{C}| \cdot N_{\text{calib}}$ 次额外 ETD 前向, 高但无架构偏置。
直觉: 直接测量「开 ETD 是否抬高真类 logit」, 绕过所有几何代理; 作为 **保底** 在 Gemma2 上最安全。

R39A 量化评分 (摘要) 对信号 s 与 sweep 窗口 $\mathcal{W}_{\text{sweep}}$, 区分力可写为

$$\text{disc}(s) = \mathbb{E}[s_\ell \mid \ell \in \mathcal{W}_{\text{sweep}}] - \mathbb{E}[s_\ell \mid \ell \notin \mathcal{W}_{\text{sweep}}]$$

(实现中用标定样本的层均值近似期望)。再配合「符号是否与假设方向一致」的覆盖率与 t_{start} 误差, 得到六路信号排名, R39B/C。

10.4 R39C 最终评测结果 (三模型 $\times$ 8 Benchmark)

R39C 确立了三种核心方法——neg_cos_am_calib (基于 cos(a,m) 的标定窗口)、emp_logit_fixed (经验 logit 增益选窗)、neg_cos_am_ps_nt (逐样本 cos(a,m) + 架构特异性 n_t) ——并在三个模型上进行全量评测 (N=100/bench)。

Qwen3-8B 结果 (N=100/bench) :

Benchmark	baseline	sweep_best	neg_cos_am_calib	emp_logit_fixed	neg_cos_am_ps_nt
BoolQ	0.820	0.870	0.860	0.900	0.850
ARC-C	0.560	0.580	0.560	0.560	0.530
TruthfulQA	0.320	0.380	0.320	0.340	0.340
CSQA	0.640	0.690	0.650	0.640	0.620
MMLU-HS-Math	0.400	0.430	0.410	0.370	0.320
GPQA-Diamond	0.380	0.440	0.330	0.360	0.330
AGIEval-Gaokao-MathQA	0.520	0.540	0.540	0.570	0.570
LogiQA	0.360	0.500	0.380	0.420	0.390

Qwen3-8B 的 emp_logit_fixed 在 BoolQ (0.900, 超越 sweep_best 的 0.870) 和 AGIEval (0.570) 上取得最优, 但在 MMLU、GPQA、LogiQA 上不如 sweep_best。

Llama3-8B 结果 (N=100/bench) :

Benchmark	baseline	sweep_best	neg_cos_am_calib	emp_logit_fixed	neg_cos_am_ps_nt
BoolQ	0.740	0.820	0.820	0.770	0.750
ARC-C	0.520	0.550	0.530	0.510	0.470
TruthfulQA	0.240	0.300	0.220	0.240	0.260
CSQA	0.600	0.660	0.630	0.610	0.610
MMLU-HS-Math	0.280	0.330	0.250	0.220	0.270
GPQA-Diamond	0.290	0.360	0.320	0.390	0.280
AGIEval-Gaokao-MathQA	0.290	0.310	0.350	0.270	0.330

Benchmark	baseline	sweep_best	neg_cos_am_calib	emp_logit_fixed	neg_cos_am_ps_nt
LogiQA	0.290	0.420	0.270	0.350	0.260

Llama3 上信号方法整体仍低于 sweep_best，但 neg_cos_am_calib 在 BoolQ 上持平 sweep_best (0.820)，emp_logit_fixed 在 GPQA 上超过 sweep_best (0.390 vs 0.360)。

Gemma2-2B 结果 (N=100/bench)：

Benchmark	baseline	sweep_best	neg_cos_am_calib	emp_logit_fixed	neg_cos_am_ps_nt
BoolQ	0.680	0.730	0.520	0.680	0.570
ARC-C	0.290	0.350	0.330	0.290	0.250
TruthfulQA	0.280	0.320	0.180	0.280	0.280
CSQA	0.210	0.280	0.160	0.210	0.200
MMLU-HS-Math	0.110	0.200	0.150	0.110	0.100
GPQA-Diamond	0.280	0.310	0.280	0.280	0.270
AGIEval-Gaokao-MathQA	0.250	0.300	0.270	0.250	0.220
LogiQA	0.220	0.250	0.230	0.220	0.220

Gemma2 上 neg_cos_am_calib 在 BoolQ 上大幅低于 baseline (0.520 vs 0.680)，双 LN 架构导致信号对 Gemma2 有害。emp_logit_fixed 基本持平 baseline，是三种方法中最安全的。

各模型条形图：




Figure 18: Qwen3 R39C 各 Benchmark 条形图

10.5 R39 核心结论

1. **neg_cos_am** ($\cos(a_l, m_l)$ 的负值区) 是目前最具跨架构潜力的信号，但仍需架构特异性调整
2. **emp_logit_fixed** 是最稳健的保底方案，三个模型上均不低于 baseline（最坏情况持平）
3. Gemma2 的双 LN 是独立挑战，需要 post-norm 张量处理
4. **sweep_best** 始终是上界，信号方法尚未系统性超越扫参结果

11. R40: BBH + GSM8K 三模型评测

11.1 实验设计

R40 将 R39C 确立的三种信号方法扩展至生成式任务评测：

- **BBH (Big-Bench Hard)**：6 个子任务 (boolean_expressions、causal_judgement、date_understanding、diagnostics、disambiguation、word_sorting)，50 条，与 lm-eval leaderboard_bbh 一致的多选题格式




Figure 19: 三模型 neg_cos_am 信号剖面图




Figure 20: 三模型热力图 (Δacc 相对 baseline)




Figure 21: 三模型宏平均总结

- **GSM8K**: 5-shot CoT + generate_until, ETD 贪婪逐步解码, 50 条样本 (max_new_tokens=256)

评测条件: baseline、neg_cos_am_calib、emp_logit_fixed、neg_cos_am_ps_nt。

11.1b 多选题 (BBH) 与生成题 (GSM8K) 的评分公式 (为何不能「一条 lm_eval 命令」跑完)

BBH (multiple_choice, 与 R39 一致): 对每个选项 $c \in \mathcal{C}$, 把题干 + few-shot + 选项续写拼成序列, 模型给出未 token 对整段续写的对数似然 $\log p_\theta(\text{continuation}_c \mid \text{prompt})$ 。常用 **长度归一化** 分数 $\text{score}_c = \ell_c^{-1} \sum_t \log p_\theta(x_t \mid x_{<t})$ (ℓ_c 为续写 token 数, 实现与 loglikelihood_mc 一致), 预测 $\hat{c} = \arg \max_c \text{score}_c$, 与 gold 比较得 accuracy。 **ETD**: 在算每个 $\log p_\theta$ 时, 对同一条 (n_e, n_t, k) 路径重复 T-block, 不改变选项拼接规则。

GSM8K (5-shot + generate_until): 记第 t 步已生成前缀 $\mathbf{x}_{\leq t}$, 模型给出下一 token 分布 $p_\theta(\cdot \mid \mathbf{x}_{\leq t})$; **baseline** 用贪婪 $\arg \max$ 递推; **ETD** 在每一步扩展前缀上调用带 T-block 的 logits (与 exp_r40 自写解码环一致)。停止准则与 lm_eval 的 until / filter 对齐后, 用正则从生成串抽取数值与 gold 比较得 exact_match。

直觉: BBH 的梯度信号全在 **logit 空间的对数似然和** 上; GSM8K 的每一步贪婪选择都是 **离散决策**, ETD 与 baseline 的轨迹可在中途 **分叉**, 故小模型 (Gemma2) 上更容易出现「ETD 每步都动一点、累积成全错」的退化。

11.2 R40 BBH 结果

Qwen3-8B (BBH 6 子任务, N=50/任务):

子任务	baseline	neg_cos_am_calib	emp_logit_fixed	neg_cos_am_ps_nt
boolean_expressions	0.900	0.920	0.940	0.880
causal_judgement	0.580	0.560	0.620	0.540
date_understanding	0.740	0.680	0.660	0.520
disambiguation_qa	0.480	0.500	0.580	0.420
logical_deduction_three_objects	0.820	0.860	0.860	0.780
object_counting	0.480	0.520	0.480	0.460
宏平均	0.667	0.673	0.690	0.600

Llama3-8B (BBH 6 子任务, N=50/任务):

子任务	baseline	neg_cos_am_calib	emp_logit_fixed	neg_cos_am_ps_nt
boolean_expressions	0.860	0.760	0.760	0.800
causal_judgement	0.540	0.500	0.540	0.520
date_understanding	0.580	0.680	0.620	0.520
disambiguation_qa	0.460	0.360	0.400	0.380
logical_deduction_three_objects	0.420	0.480	0.480	0.520
object_counting	0.460	0.500	0.520	0.480
宏平均	0.553	0.547	0.553	0.537

Gemma2-2B (BBH 6 子任务, N=50/任务):

子任务	baseline	neg_cos_am_calib	emp_logit_fixed	neg_cos_am_ps_nt
boolean_expressions	0.600	0.380	0.600	0.380
causal_judgement	0.500	0.500	0.520	0.500
date_understanding	0.360	0.360	0.360	0.360
disambiguation_qa	0.320	0.360	0.320	0.360
logical_deduction_three_objects	0.400	0.400	0.400	0.380
object_counting	0.200	0.060	0.200	0.060
宏平均	0.397	0.343	0.400	0.340

11.3 R40 GSM8K 结果

5-shot CoT, 贪婪 ETD 解码 (max_new_tokens=256, N=50) :

模型	baseline	neg_cos_am_calib	emp_logit_fixed	neg_cos_am_ps_nt
Qwen3-8B	0.900	0.940	0.900	0.900
Llama3-8B	0.520	0.400	0.520	0.340
Gemma2-2B	0.040	0.020	0.040	0.020

Qwen3-8B 上 neg_cos_am_calib 在 GSM8K 上达到 0.940, 超过 baseline (0.900) +4%, 是 R40 中最显著的单点提升。

各模型 BBH 结果可视化:




Figure 22: R40 BBH 各模型 Accuracy 分组图

11.4 R40 核心结论

1. Qwen3-8B 上 neg_cos_am_calib 和 emp_logit_fixed 在 BBH 和 GSM8K 上整体提升 baseline, 是三个模型中唯一持续提升
2. Llama3-8B 整体改善有限, BBH 宏平均与 baseline 持平, GSM8K 部分方法有损
3. Gemma2-2B 的 neg_cos_am_calib 和 neg_cos_am_ps_nt 在 BBH 上损伤 baseline (boolean_expressions 从 0.600 降至 0.380), 双 LN 架构问题未解决




Figure 23: R40 BBH Accuracy 热力图




Figure 24: R40 BBH 宏平均对比




Figure 25: R40 GSM8K exact_match 对比

4. 生成式任务 (GSM8K) 比多选题对 ETD 更敏感, ETD 的贪婪逐步解码在 Llama/Gemma 上容易产生退化

12. R41: 回流敏感性与 Jacobian 衰减复合信号

12.1 R41 两个方向: 公式、门控规则与直觉

Direction 1 — 回流敏感度 ρ (reflux_rho_gate) 固定冠军 T-block $(n_e, n_t) = (8, 14)$ (与 R41 JSON champion_ne_nt 一致)。记末 token 在 仅跑完第一遍 ETD 循环 ($k=1$) 与 跑完两遍 ($k=2$) 时的 logits 向量分别为 $\mathbf{z}^{(1)}, \mathbf{z}^{(2)} \in \mathbb{R}^{|\mathcal{V}|}$ (实现与 etd_forward_logits 一致)。定义 logit 增量

$$\delta_{\text{logit}} = \mathbf{z}^{(2)} - \mathbf{z}^{(1)}.$$

令 $\hat{y} = \arg \max_c z_c^{(1)}$ 为无标签的「模型在第一次循环后自认的 top-1 类」(oracle-free)。回流标量定义为

$$\rho = \frac{(\delta_{\text{logit}})_{\hat{y}}}{\|\delta_{\text{logit}}\|_2 + \varepsilon} \in [-1, 1].$$

直觉: ρ 度量第二次循环把 logit 向量往自己当前最信的那一维推了多少「分量占比」。 $\rho > 0$: 第二遍在强化已有.argmax 决策 (像「自我一致的后处理」); $\rho < 0$: 第二遍在削弱该决策 (更像噪声或纠错但未对准真标签)。在校准集 $\mathcal{D}_{\text{cal}}$ 上算 $\{\rho_i\}$, 取 $\tau = \text{median}(\rho_i)$; 评测样本若 $\rho > \tau$ 则采用 $k=2$ 的 ETD 输出, 否则退回 baseline 单次前向。**优点:** 不搜窗; **风险:** $\hat{y}$ 未必是正确答案, ρ 高只说明「更自信」而非「更对」——故 MC 上常与 baseline 持平。

Direction 2 — neg_cos_am $\times$ prop_attn_sens 复合剖面 (neg_cos_am_prop_attn) (1) 竞争深度: 在探针层集合 $\mathcal{P}$ (R41 取每 4 层如 $\{8, 12, 16, 20, 24, 28\}$) 上已有

$$\text{neg_cos_am}(\ell) = -\cos_{\text{sim}}(\mathbf{a}_\ell, \mathbf{m}_\ell).$$

(2) 注意力写入的传播灵敏度：与 § 7.3 相同 hook 注入，但扰动向量改为 注意力子层输出 的单位方向 $\hat{\mathbf{a}}_\ell = \mathbf{a}_\ell / (\|\mathbf{a}_\ell\|_2 + \varepsilon)$ ：

$$\text{PropAttnSens}_\ell(x) = \text{JSD}\left(P, Q(\varepsilon_{\text{inj}} \hat{\mathbf{a}}_\ell)\right),$$

其中 $P, Q(\cdot)$ 与 § 7.3 定义相同（末 token softmax logits）。

(3) 复合剖面：

$$\text{Compound}(\ell; x) = \text{neg_cos_am}(\ell) \cdot \text{PropAttnSens}_\ell(x).$$

直觉：neg_cos_am 大表示 强竞争；PropAttnSens 大表示 沿 attention 写入方向的扰动仍能强烈改变最终答案分布（该方 Decoder 中「活得下来」）。二者相乘强调「又竞争、又敏感」的层位——比单独用 $\mathbf{C}_\ell$ 更接近「ETD 在改 attention 已读入的内容」这一机制。**选窗**：在标定集上对 $\text{Compound}(\ell)$ 做层均值 $\overline{\text{Compound}}_\ell$ ，再用与 neg_cos_am_calib 相同的 **select_calib_global(..., calib_nt)** 取固定长度窗口（R41 计划 calib_nt 与 R39C 一致）。

与 R36 的差异：R36 用 $\hat{\mathbf{C}}_\ell$ （交换子）与 随机 $\hat{\mathbf{r}}$ 对照；R41 用 $\hat{\mathbf{a}}_\ell$ 且 直接与竞争标量相乘，问的是「这条上下文写入通道是否既是矛盾焦点、又对输出高杠杆」。

12.2 实验设计

条件	说明
baseline	原始单次前向
neg_cos_am_calib	R39C 参考线
emp_logit_fixed	R39C 参考线
reflux_rho_gate	Direction 1: champion 窗 + 逐样本 ρ 门控
neg_cos_am_prop_attn	Direction 2: neg_cos_am $\times$ prop_attn 复合窗

评测范围：Qwen3-8B only, BoolQ (N=40)、ARC-C (N=40)、GPQA-Diamond (N=40)，以及 BBH 6 子任务 (limit=20/task)。

12.3 R41 实验结果

MC Benchmark 结果 (N=40, 冠军窗口 n_e=8, n_t=14)：

Benchmark	baseline	neg_cos_am_calib	emp_logit_fixed	reflux_rho_gate	neg_cos_am_prop_attn
BoolQ	0.840	0.840	0.800	0.840	0.840
ARC-C	0.520	0.440	0.560	0.520	0.520
GPQA-Diamond	0.400	0.320	0.280	0.400	0.360

BBH 宏平均结果 (6 子任务, N=20/task)：

条件	BBH 宏平均 Accuracy	Δ vs baseline
baseline	0.653	0.000
neg_cos_am_calib	0.736	+0.083
emp_logit_fixed	0.708	+0.056
reflux_rho_gate	0.667	+0.014
neg_cos_am_prop_attn	0.694	+0.042

BBH 逐子任务对比 (N=20/task)：

子任务	baseline	neg_cos_am_calib	emp_logit_fixed	reflux_rho_gate	neg_cos_am_prop_attn
boolean_expressions	0.700	0.850	0.800	0.700	0.850
causal_judgment	0.700	0.700	0.600	0.700	0.650

子任务	baseline	neg_cos_am_calib	emp_logit_fixed	reflux_rho_gate	neg_cos_am_prop_attn
date_understanding	0.650	0.750	0.750	0.650	0.750
disambiguation_qa	0.400	0.650	0.700	0.700	0.600
logical_deduction	0.750	0.800	0.750	0.750	0.750
object_counting	0.550	0.650	0.700	0.550	0.600

综合条形图：





Figure 26: R41 Qwen3 全 Benchmark 精度对比

12.4 R41 核心发现

- 1. **neg_cos_am_calib** 在 BBH 上取得最强提升 (+8.3%)，在 6 个子任务中 5 个最优或并列最优，进一步证实了 cos(a,m) 信号的有效性
- 2. **reflux_rho_gate** 在 MC benchmark 上表现最保守 (BoolQ = baseline, ARC-C = baseline, GPQA = baseline)， ρ 门控没有带来额外增益
- 3. **neg_cos_am_prop_attn** (Direction 2) 在 BBH 上 +4.2%，优于 reflux_rho_gate，但不如 neg_cos_am_calib 单独使用
- 4. MC benchmark 与 BBH 的信号效果分化：neg_cos_am_calib 在 MC 上有时反而低于 baseline (ARC-C: 0.440 vs 0.520)，但在 BBH (推理密集型多步题目) 上效果显著

13. 纵向总结：十轮迭代的信号探索轨迹

13.1 信号探索路径图



R34: 方向 + 跨模块信号——发现 $\cos(a_l, m_l) < 0$ 定位竞争区 ★
↓
R35: 精确交换子 Term1 + Term2——norm 随深度单调增长, 无法定位 T-block
↓
R36: 方向特异性传播增益 directional_advantage——比率去除深度混淆, $\cos_{res}$ 作为 T-block 选窗信号
↓
R37: $\cos_{res}$ 信号引导 ETD 选层——onset_cos8 在 MMLU 达到 oracle 水平 ★
↓
R38: 全 8 Benchmark + 标定阶段—— $\cos_{res}$ 弱有效, 始终无法超越 sweep_best
↓
R39: 跨架构根因分析—— $\cos_{am}$ 是更鲁棒信号; empirical logit gain 是保底方案 ★
↓
R40: BBH + GSM8K 三模型——Qwen3 持续正向, Llama/Gemma 需单独处理
↓
R41: 回流 ρ 门控 + compound 复合信号——BBH +8.3% (neg_cos_am_calib) ★

13.2 六个主要信号及其最终评价

信号	轮次	理论依据	最终评价
rc_global (收缩率)	R32	J_F 的局部谱半径	☒ 与权重锁定, std≈0.02, 无输入区分力
ffn_gini / attn_spectral_gap	R33	激活集稀疏度 / 快权重主特征值	☒ 反映架构属性, 样本间 std 极低
cross_cos_a_m = $\cos(a_l, m_l)$	R34	Attention/FFN 方向竞争	✓ T-block 区间稳定负值; 选窗信号
commutator_norm C_l	R35	Attention-FFN 非对易度	☒ 随深度单调增, 非 T-block 函数
directional_advantage	R36	C_l 方向的传播特异性	△ 中位数有 T-block 结构但高方差
cos_res = $\cos(\text{Term1}, \Delta h_l)$	R36→R38	Attention 对 FFN 的方向偏转	△ Qwen3 弱有效, 跨架构失效
neg_cos_am_calib	R39→R41	$\cos(a,m)$ 负值区标定窗口	✓ BBH +8.3% (R41), GSM8K +4%
emp_logit_fixed	R39→R40	经验 logit 增益搜窗	✓ 最稳健保底方案, 三架构均不损 baseline
reflux_rho_gate	R41	k=2 vs k=1 的 logit 差方向	△ 保守, MC 持平 baseline, BBH +1.4%

13.3 各 Benchmark 最终最优方法汇总 (Qwen3-8B)

以 R39C 结果为基准 (N=100/bench) :

Benchmark	baseline	sweep_best	最佳信号方法	最佳信号准确率	vs sweep_best
BoolQ	0.820	0.870	emp_logit_fixed	0.900	+0.030 ✓
ARC-C	0.560	0.580	neg_cos_am_calib / baseline	0.560	-0.020
TruthfulQA	0.320	0.380	neg_cos_am_ps_nt / emp_logit_fixed	0.340	-0.040
CSQA	0.640	0.690	neg_cos_am_calib	0.650	-0.040
MMLU-HS-Math	0.400	0.430	neg_cos_am_calib	0.410	-0.020
GPQA-Diamond	0.380	0.440	neg_cos_am_calib	0.330	-0.110
AGIEval	0.520	0.540	neg_cos_am_calib / emp_logit_fixed	0.570	+0.030 ✓
LogiQA	0.360	0.500	emp_logit_fixed	0.420	-0.080

结论: 目前的信号方法在 BoolQ 和 AGIEval 上已经能够超越 sweep_best, 但在 GPQA-Diamond、LogiQA 等推理密集任务上仍有较大差距。

13.4 主要发现总结

- 一阶信号的信息上限极低: 在 per-sample 层面, 所有尝试过的标量统计量与 oracle_gain 的 Spearman $|\rho|$ 均未超过 0.14 (R29 历史天花板), 意味着单次前向的激活统计量无法编码“第二遍是否有益”的决策边界。
- 几何方向信号是唯一突破口: $\cos(a_l, m_l)$ 通过捕获 attention 与 FFN 的方向竞争, 成为唯一一个在多个 benchmark 和多个架构上展现出系统性结构的信号。其负值区域 (attention 与 FFN 互相对抗) 与 ETD 有效的 T-block 区间高度吻合。
- 经验标定 (empirical logit gain) 是最可靠的保底方案: 通过 N_CALIB=20 个样本实际运行 ETD 并测量 logit 增益, 无需任何架构假设, 在三个模型上均不损 baseline, 且在 BoolQ 等任务上取得稳定提升。

4. **跨架构泛化仍是未解难题**: Qwen3-8B 上有效的信号在 Llama3-8B 和 Gemma2-2B 上效果大幅衰减甚至产生负效果, $\cos_res$ 全部在 L10 达峰) 和 “双重 LN 破坏信号物理意义” (Gemma2 Term1 近似误差)。
5. **生成式任务 (GSM8K) 对 ETD 的挑战更大**: ETD 的贪婪逐步解码在生成过程中需要对每一个 token 决策都使用 ETD, 计算代价约为 baseline 的 k 倍, 且在 Llama3 和 Gemma2 上容易产生分布偏移。
6. **BBH (多步推理) 是 ETD 最有潜力的应用场景**: R41 的 BBH 结果显示 $\neg_cos_am_calib$ 在 6 个子任务上宏平均 +8.3%, 说明需要多步推理协调的任务对 ETD 的第二遍 “重新整合” 更加敏感。

13.5 下一步研究方向

基于十轮迭代的经验积累, 以下方向最有潜力:

1. **Qwen3 专项优化**: 在已证明有效的 $\neg_cos_am_calib$ 基础上, 探索 n_t 的精细搜索 (目前的 {4,6,8} 空间可能错过最优 $n_t=14$)
2. **架构适配 $\cos(a,m)$** : 针对 Llama3 的 RoPE 偏差和 Gemma2 的双 LN, 设计架构特异性的 $\cos(a,m)$ 计算修正
3. **BBH 专项扩展**: BBH 结果显示多步推理是最有效的应用域, 可以扩展到更多推理子任务和更大样本量
4. **ρ 门控的精细化**: R41 的 reflux_rho_gate 在 MC 任务上持平 baseline, 但在 BBH 上只有 +1.4%。可能需要更大的标定 ($\rightarrow 50$) 才能使中位数阈值 τ 更可靠
5. **$k > 2$ 的探索**: 目前所有实验均固定 $k=2$, 但 BBH 的强提升暗示 $k=3$ 或 $k=4$ 在多步推理任务上可能有额外收益

附录 A: 参数配置汇总

A.1 各实验的模型与环境配置

轮次	模型	n_layers	$hidden_size$	$intermediate_size$	注意力头数
R32-R38	Qwen3-8B	36	4096	11264	32
R38+	Llama3-8B	32	4096	14336	32
R38+	Gemma2-2B	26	2304	9216	8

A.2 实验规模汇总

轮次	样本数/bench	Benchmark 数	总样本规模
R32 Phase0	20	4	80
R32 Phase1	200	4	800
R33 Phase1	50	5	250
R34	20	8	160
R35	20	8	160
R36	100	8	800
R37	100	3	300
R38	100	8	800
R39C	100	8×3 模型	2400
R40 BBH	50/subtask	$6 \text{ sub} \times 3$ 模型	900
R40 GSM8K	50	3 模型	150
R41	40 MC + 20 BBH	$3 + 6 \text{ sub}$	240

A.3 代码文件索引

轮次	主要脚本	输出目录
R32	experiments/exp_r32_phase*.py	results/r32_*, figures/r32_*
R33	experiments/exp_r33_phase*.py	results/r33_*, figures/r33_*
R34	experiments/exp_r34_cross_memory_probe.py	results/r34_*, figures/r34_cross_memory/
R35	experiments/exp_r35_commutator_probe.py	results/r35_*, figures/r35_commutator/

轮次	主要脚本	输出目录
R36	experiments/exp_r36_propagation_etd.py	results/r36_*, figures/r36_propagation/
R37	experiments/exp_r37_signal_guided_loop.py	results/r37_*, figures/r37_signal_loop/
R38	experiments/exp_r38_signal_full_benchmark.py	results/r38_*, figures/r38_signal_full/
R39C	experiments/exp_r39c_final.py	results/r39c_*, figures/r39c_final_*/
R40	experiments/exp_r40_bbh_gsm8k_etd.py	results/r40_*, figures/r40_bbh_gsm8k/
R41	experiments/exp_r41_reflux_jac_etd.py	results/r41_*, figures/r41_qwen3/

本文档综合了 R32–R41 的全部研究计划、实验数据与可视化结果，记录了 ETD 信号探索从理论构建到实验验证的完整轨迹。tmp/loop_layer/experiments/results/ 目录下各实验的 JSON 结果文件及相应的 PNG 图表。